



دانشگاه مازندران

دانشکده مهندسی و فناوری
گروه مهندسی کامپیوتر

پروژه کارشناسی مهندسی کامپیوتر

بازطراحی شبکه‌های عصبی گراف پرشی برای پیش‌بینی تعاملات زیست‌مولکولی

Redesigning Skip-Graph Neural Networks for Predicting Biomolecular Interactions

نگارنده: امیررضا نعمتی

شماره دانشجویی: 40113160281830

استاد راهنما: دکتر خدیجه آقاجانی

نیم‌سال دوم سال تحصیلی ۱۴۰۴-۱۴۰۵

چکیده

پیش‌بینی برهم‌کنش‌های زیست‌مولکولی - شامل تعاملات دارو-هدف، دارو-دارو، پروتئین-پروتئین و ژن-بیماری - یکی از چالش‌های بنیادین در زیست‌شناسی سامانه‌ها و کشف دارو است. مدل SkipGNN (هوانگ و همکاران، ۲۰۲۰) با تزریق گراف پرش ۲-گام به شبکه‌های عصبی گراف، عملکرد قابل‌توجهی در بنچمارک‌های استاندارد گزارش کرد. با این حال، بازبینی دقیق تئوریک و تجربی در این پژوهش، چهار محدودیت بنیادین در این مدل شناسایی کرد: بن‌بست هندسی عملگر A^2 در گراف‌های دوقطبی، حذف اطلاعات چگالی بر اثر باینری‌سازی، تنگنای ظرفیت دیکودر خطی، و سوگیری ساختاری پروتکل ارزیابی یکنواخت.

برای رفع این محدودیت‌ها، چهار مدل در چارچوب یک پایپ‌لاین یکپارچه طراحی و پیاده‌سازی شدند: AMS-SkipGNN (پرش پیوسته تخصیص منابع، گیتینگ تطبیقی، و دیکودر تانسوری ۴-گانه)، SkipGATv2 (توجه پویا لبه‌ای تنک)، ThreeHopSkipGNN (مسیرهای چندمقیاسی ۱/۲/۳-گام)، و ContrastiveSkipGNN (هم‌ترازی خودنظارتی با زیان InfoNCE). ارزیابی بر اساس پروتکل دوگانه - بانک یکنواخت و بانک سخت آگاه از درجه - روی چهار دیتاست استاندارد (GDI، PPI، DDI، DTI) با ۳ سید تصادفی انجام شد.

نتایج نشان می‌دهند که در بانک سخت، مدل‌های پیشنهادی بهبود قابل‌توجهی نسبت به SkipGNN دارند: در AMS، DDI به 0.912 در مقابل 0.724 می‌رسد؛ در PPI، SkipGATv2 به 0.778 در مقابل 0.622؛ و در DTI و GDI، بهبود در محدوده 0.10+ تا 0.12+ واحد درصد است. در دیتاست DTI، سه مدل AMS، SkipGATv2 و 3-hop از نظر آماری هم‌سطح هستند (بازه‌های انحراف معیار هم‌پوشان). در دیتاست GDI، هوریستیک تحلیلی تخصیص منابع با 0.842 بالاتر از تمام مدل‌های عصبی قرار می‌گیرد که به‌عنوان یک بینش مهم درباره محدودیت‌های ذاتی مدل‌های عصبی در گراف‌های بسیار بزرگ و تنک با ویژگی‌های هویتی بحث شده است.

واژگان کلیدی: پیش‌بینی پیوند، شبکه‌های عصبی گراف، SkipGNN، گراف‌های دوقطبی، تخصیص منابع، پروتکل ارزیابی دوگانه

فهرست مطالب

آ	چکیده
۱	۱ مقدمه و کلیات پژوهش
۱	۱-۱ بستر پژوهش و ضرورت پیش‌بینی محاسباتی تعاملات زیست‌مولکولی
۲	۱-۲ صورت‌بندی مسئله: پیش‌بینی پیوند در گراف‌های زیستی
۳	۱-۳ مدل مرجع و محدودیت‌های شناسایی‌شده
۴	۱-۴ پرسش‌ها و فرضیات پژوهش
۵	۱-۵ مدل‌های پیشنهادی و نوآوری‌های پژوهش
۶	۱-۵-۱ نوآوری‌های روش‌شناختی
۶	۱-۵-۲ انتخاب آگاهانه ویژگی‌های ورودی
۶	۱-۶ دستاوردهای عددی شاخص
۷	۱-۷ ساختار فصول گزارش
۸	۲ مبانی نظری، ادبیات موضوع و نقد ساختاری مدل مرجع
۸	۲-۱ مبانی نظری یادگیری بازنمایی روی گراف
۸	۲-۱-۱ تعاریف پایه و نمادگذاری ریاضی
۸	۲-۱-۲ پارادایم انتشار پیام (Message Passing)
۹	۲-۱-۳ شبکه‌های پیچشی گراف و نرمال‌سازی لاپلاسی
۹	۲-۱-۴ چالش بیش‌هموارسازی
۱۰	۲-۲ پیش‌بینی پیوند و خطوط مبنای هوریستیک
۱۰	۲-۲-۱ صورت‌بندی مسئله
۱۰	۲-۲-۲ شاخص‌های هوریستیک غیرپارامتری
۱۱	۲-۳ تشریح مدل مرجع SkipGNN
۱۱	۲-۳-۱ ساخت گراف پرش‌باینری

۱۱	۲-۳-۲ معماری ادغام دوکاناله
۱۱	۲-۳-۳ دیکودر خطی
۱۲	۲-۴ نقد ساختاری و ریاضی SkipGNN
۱۲	۲-۴-۱ بن بست هندسی در گراف‌های دوقطبی (اثبات ریاضی)
۱۳	۲-۴-۲ حذف اطلاعات چگالی بر اثر باینری‌سازی
۱۳	۲-۴-۳ تنگنای ظرفیت دیکودر خطی
۱۴	۲-۵ نقد روش‌شناختی پروتکل ارزیابی
۱۴	۲-۵-۱ سوگیری درجه در نمونه‌برداری منفی یکنواخت
۱۴	۲-۵-۲ ناسازگاری‌های پیاده‌سازی در کد مرجع
۱۴	۲-۶ جمع‌بندی: شکاف پژوهشی و ضرورت مدل‌های پیشنهادی
۱۶	۳ داده‌ها، توپولوژی گراف‌های زیستی و پروتکل ارزیابی دوگانه
۱۶	۳-۱ مجموعه‌های داده معیار و تحلیل ساختاری آن‌ها
۱۶	۳-۱-۱ پایگاه داده برهم‌کنش دارو-دارو (BioSNAP-DDI)
۱۶	۳-۱-۲ پایگاه داده برهم‌کنش پروتئین-پروتئین (HuRI-PPI)
۱۷	۳-۱-۳ پایگاه داده برهم‌کنش دارو-هدف (BioSNAP-DTI)
۱۷	۳-۱-۴ پایگاه داده برهم‌کنش ژن-بیماری (DisGeNET-GDI)
۱۷	۳-۲ پایپ‌لاین بدون نشت داده (Leak-Free Pipeline)
۱۸	۳-۲-۱ انتخاب آگاهانه ویژگی‌های ورودی
۱۹	۳-۲-۲ ساخت تنسورهای تنک کوالس شده
۱۹	۳-۳ عملگرهای پرش توپولوژیک (Topological Skip Operators)
۱۹	۳-۳-۱ عملگر پرش باینری بدون سلف‌لوپ (Binary Skip)
۱۹	۳-۳-۲ عملگر پرش پیوسته تخصیص منابع (Resource Allocation Skip)
۲۰	۳-۳-۳ عملگر مسیر بازگشت ۳-گام (Bipartite 3-Walk Return)
۲۰	۳-۳-۴ نرمال‌سازی لاپلاسی متقارن ایمن (Safe Laplacian Normalization)
۲۱	۳-۴ پروتکل ارزیابی دوگانه (Dual-Bank Evaluation Protocol)
۲۱	۳-۴-۱ بانک آزمون یکنواخت (Uniform Test Bank)

۲۱	۳-۴-۲	بانک آزمون سخت آگاه از نوع موجودیت (Hard Test Bank)
۲۲	۳-۴-۳	اصول حاکم بر پروتکل سخت
۲۳	۳-۵	معیارهای ارزیابی و انتخاب آستانه
۲۴	۴	فرمولاسیون ریاضی و معماری روش‌های پیشنهادی
۲۴	۴-۱	چارچوب مفهومی یکپارچه
۲۴	۴-۲	مدل پیشنهادی ۱: AMS-SkipGNN
۲۴	۴-۲-۱	معادلات انتشار پیام در لایه اول انکودر
۲۵	۴-۲-۲	واحد گیتینگ تطبیقی باقی‌مانده
۲۶	۴-۲-۳	معادلات انتشار پیام در لایه دوم انکودر
۲۶	۴-۲-۴	دیکودر تانسوری تعاملی ۴گانه
۲۷	۴-۳	مدل پیشنهادی ۲: SkipGATv2
۲۷	۴-۳-۱	لایه توجه تنک SparseGATv2Layer
۲۸	۴-۳-۲	معماری انکودر متقابل دوکاناله
۲۹	۴-۳-۳	الگوریتم توجه تکه‌ای برای گراف‌های کلان
۲۹	۴-۴	مدل پیشنهادی ۳: ThreeHopSkipGNN
۲۹	۴-۴-۱	انکودر سه‌شاخه چندمقیاسی
۳۰	۴-۴-۲	گیتینگ برداری سه‌کاناله با سافت‌مکس
۳۱	۴-۵	مدل پیشنهادی ۴: ContrastiveSkipGNN
۳۱	۴-۵-۱	انکودر دو نمایی مستقل
۳۱	۴-۵-۲	سرهای تصویر غیرخطی
۳۲	۴-۵-۳	تابع زیان تقارنی InfoNCE
۳۳	۴-۶	مدل‌های خط مبنا
۳۳	۴-۷	نردبان ابلیشن مدولار
۳۴	۵	پروتکل آموزش، آزمایش‌های تجربی و تحلیل جامع نتایج
۳۴	۵-۱	پروتکل آموزش و تنظیمات آزمایشگاهی

۳۴	۵-۱-۱	زیرساخت محاسباتی و استراتژی آموزش
۳۴	۵-۱-۲	هایپرپارامترهای مشترک
۳۴	۵-۱-۳	تنظیمات اختصاصی هر دیتاست و پروتکل مقایسه
۳۵	۵-۱-۴	مکانیزم توقف زودهنگام و انتخاب آستانه
۳۶	۵-۱-۵	ملاحظات آماری و معیار پراکندگی
۳۶	۵-۲	نتایج تجربی کلان: ارزیابی هفت مدل
۳۶	۵-۲-۱	ماتریس جامع نتایج AUPRC
۳۷	۵-۲-۲	تحلیل هم‌سطحی آماری در دیتاست DTI
۳۷	۵-۲-۳	ماتریس نتایج AUROC و F1
۳۷	۵-۳	تحلیل تفصیلی نمودارها
۳۷	۵-۳-۱	شکل ۱: مقایسه همزمان آزمون یکنواخت و سخت
۳۸	۵-۳-۲	شکل ۲: نردبان ابلیشن
۳۹	۵-۳-۳	شکل ۳: مقاومت در برابر حذف یال
۴۰	۵-۳-۴	شکل ۴: منحنی‌های دقت-بازخوانی
۴۲	۵-۳-۵	شکل ۵: نقشه حرارتی عملکرد
۴۲	۵-۳-۶	شکل ۶: دلتای بهبود نسبت به AMS
۴۴	۵-۳-۷	شکل ۷: توزیع بین‌سیدی
۴۵	۵-۳-۸	شکل ۸: مقایسه بر حسب AUROC
۴۵	۵-۳-۹	شکل ۹: منحنی‌های یادگیری
۴۷	۵-۳-۱۰	شکل ۱۰: شاخص F1 در آستانه بهینه
۴۷	۵-۴	تحلیل فضاهاى نهفته با t-SNE
۴۹	۵-۵	خلاصه یافته‌های کلیدی فصل
۵۱	۶	بحث، تحلیل پاشنه‌های آشیل، نتیجه‌گیری و افق‌های آینده
۵۱	۶-۱	بحث مکانیکی و تبیین چرایی نتایج (Mechanistic Discussion)
۵۱	۶-۱-۱	نقش عملگر پیوسته تخصیص منابع در مهار سوگیری هاب‌ها
۵۱	۶-۱-۲	حل بن‌بست هندسی دوقطبی با مسیرهای ۳-گام

۵۲	۶-۱-۳	هم‌افزایی گیتینگ تطبیقی و دیکودر تانسوری تعاملی
۵۲	۶-۱-۴	تمایز عملکرد بین دیتاست‌ها و کارآمدی SkipGATv2
۵۳	۶-۲	تحلیل پاشنه‌های آشیل و محدودیت‌های روش‌شناختی
۵۳	۶-۲-۱	چالش گراف‌های کلان و تنک: برتری هوریستیک در GDI
	۶-۲-۲	محدودیت ویژگی‌های هویتی (One-Hot) و افت مکانیزم توجه در
۵۳		گراف کلان
۵۴	۶-۲-۳	محدودیت‌های آماری و تعداد سیدها
۵۴	۶-۲-۴	محدودیت مقیاس‌پذیری
۵۴	۶-۳	نتیجه‌گیری و پاسخ به پرسش‌های پژوهش
۵۵	۶-۴	افق‌های پژوهشی و کارهای آینده
۵۵	۶-۴-۱	تزریق ویژگی‌های چندوجهی بیوشیمیایی پیش‌آموزش‌دیده
۵۶	۶-۴-۲	معماری ترکیبی ۳-گام و یادگیری خودنظارتی
۵۶	۶-۴-۳	تعمیم به گراف‌های دانش ناهمگن چندنوعی
۵۶	۶-۴-۴	توسعه الگوریتم‌های شتاب‌دهی سخت‌افزاری
۵۶	۶-۴-۵	اعتبارسنجی آماری با سیدهای بیشتر
۵۷	۶-۴-۶	معیارهای کمی برای فضای نهفته
۵۸		مراجع
۶۱		Abstract

فهرست تصاویر

۳۸	۵-۱	مقایسه AUPRC یکنواخت و سخت
۳۹	۵-۲	نردبان ابلیشن AMS در DTI
۴۰	۵-۳	مقاومت در برابر حذف یال
۴۱	۵-۴	منحنی‌های دقت-بازخوانی
۴۲	۵-۵	نقشه حرارتی Hard AUPRC
۴۳	۵-۶	دلتای Hard AUPRC نسبت به AMS
۴۴	۵-۷	توزیع بین‌سیدی Hard AUPRC
۴۵	۵-۸	مقایسه AUROC یکنواخت و سخت
۴۶	۵-۹	منحنی‌های یادگیری
۴۷	۵-۱۰	شاخص F1 در آستانه بهینه
۴۸	۵-۱۱	تصویرسازی t-SNE لایه آخر

فهرست جداول

۱-۱	بهبود مطلق نسبت به SkipGNN در Hard AUPRC (واحد درصد)	۶
۲-۱	فرمولاسیون شاخص‌های هوریستیک کلاسیک	۱۰
۲-۲	مقایسه محدودیت‌های SkipGNN و راه‌حل‌های پیشنهادی	۱۵
۳-۱	مشخصات آماری و توپولوژیک چهار بنچمارک استاندارد	۱۶
۳-۲	خلاصه عملگرهای توپولوژیک و مدل‌های مصرف‌کننده	۲۱
۴-۱	خلاصه چهار مدل پیشنهادی و محدودیت هدف‌گذاری شده	۲۴
۴-۲	مشخصات فنی خطوط مبنای پیاده‌سازی شده	۳۳
۴-۳	ساختار گام‌های چهار گانه مطالعه ابلیشن	۳۳
۵-۱	هایپرپارامترهای مشترک آموزش	۳۵
۵-۲	تنظیمات اختصاصی دیتاست‌ها و اعتبار مقایسه	۳۵
۵-۳	نتایج AUPRC در بانک‌های یکنواخت و سخت (میانگین $\pm$ انحراف معیار، ۳ سید)	۳۶
۵-۴	نتایج Hard AUROC و F1 در آستانه بهینه τ^* (میانگین $\pm$ انحراف معیار، ۳ سید)	۳۷
۵-۵	نتایج نردبان ابلیشن در دیتاست DTI (Hard AUPRC)	۳۸
۵-۶	تحلیل تطبیقی ویژگی‌های بصری مانیفولد فضای نهفته	۴۹
۵-۷	بهبود مطلق نسبت به SkipGNN در Hard AUPRC	۴۹
۶-۱	خلاصه پاسخ‌های پژوهش به پرسش‌های پنج‌گانه مطرح‌شده در فصل اول	۵۵

فصل ۱

مقدمه و کلیات پژوهش

۱-۱ بستر پژوهش و ضرورت پیش‌بینی محاسباتی تعاملات زیست‌مولکولی

شناخت و پیش‌بینی برهم‌کنش‌های میان موجودیت‌های زیست‌مولکولی^۱ یکی از ارکان بنیادین زیست‌شناسی سامانه‌ها^۲ و فرایند کشف دارو^۳ به شمار می‌رود. با گسترش فناوری‌های آزمایشگاهی با توان عملیاتی بالا^۴، حجم قابل‌توجهی از داده‌های تعاملی در پایگاه‌های داده عمومی انباشته شده است. با این وجود، فضای برهم‌کنش‌های بالقوه به مراتب بزرگ‌تر از فضای مشاهده‌شده است و آزمون تجربی کامل آن با محدودیت‌های هزینه و زمان مواجه است^۵. در این راستا، روش‌های محاسباتی غربال‌گری مجازی^۶ به عنوان ابزار اولویت‌بندی و کاهش فضای جست‌وجو جایگاه ویژه‌ای یافته‌اند.

تعاملات زیست‌مولکولی مورد بررسی در این پژوهش در چهار دسته ساختاری طبقه‌بندی می‌شوند:

-- **برهم‌کنش دارو-هدف (DTI):** پیش‌بینی پیوند فیزیکی یا مهاری میان یک مولکول دارویی و یک پروتئین هدف. این تعاملات هسته اصلی فارماکودینامیک^۷ و کشف اهداف درمانی را تشکیل می‌دهند.

-- **برهم‌کنش دارو-دارو (DDI):** بررسی تداخلات فارماکوکینتیک^۸ و فارماکودینامیک ناشی از مصرف همزمان چند دارو (پلی‌فارماسی)^۹.

-- **برهم‌کنش پروتئین-پروتئین (PPI):** نگاشت شبکه فیزیکی و عملکردی پروتئین‌ها در قالب اینتراکتوم سلولی^{۱۰}.

-- **برهم‌کنش ژن-بیماری (GDI):** شناسایی همبستگی‌های میان دگرگونی‌های ژنتیکی و فنوتیپ‌های بیماری‌زا بر پایه مطالعات هم‌خوانی سراسر ژنوم^{۱۱}.

^۱ زیست‌مولکولی (Biomolecular)

^۲ زیست‌شناسی سامانه‌ها (Systems Biology)

^۳ کشف و بازکاربردپذیری دارو (Drug Discovery & Repurposing)

^۴ غربال‌گری با توان عملیاتی بالا (High-Throughput Screening)

^۵ هزینه‌های بالای مراحل پیش‌بالینی و نرخ شکست در فازهای بالینی.

^۶ غربال‌گری مجازی (Virtual Screening)

^۷ فارماکودینامیک (Pharmacodynamics): مطالعه اثرات بیوشیمیایی و فیزیولوژیکی دارو بر بدن.

^۸ فارماکوکینتیک (Pharmacokinetics): مطالعه جذب، توزیع، متابولیسم و دفع دارو.

^۹ پلی‌فارماسی (Polypharmacy): مصرف همزمان چندین دارو توسط یک بیمار.

^{۱۰} اینتراکتوم (Interactome): مجموعه کامل برهم‌کنش‌های مولکولی در یک سلول یا ارگانیسم.

^{۱۱} مطالعات هم‌خوانی سراسر ژنوم (Genome-Wide Association Studies).

نمایش یکپارچه این تعاملات در قالب شبکه‌های پیچیده زیستی، زمینه را برای به‌کارگیری الگوریتم‌های یادگیری بازنمایی روی گراف^{۱۲} فراهم می‌کند.

۱-۲ صورت‌بندی مسئله: پیش‌بینی پیوند در گراف‌های زیستی

از منظر علوم رایانه، پیش‌بینی تعاملات زیست‌مولکولی به‌صورت مسئله پیش‌بینی پیوند در شبکه‌ها^{۱۳} صورت‌بندی می‌شود. شبکه زیستی به‌صورت گراف $G = (\mathcal{V}, \mathcal{E})$ مدل می‌گردد که در آن مجموعه گره‌ها با کاردینالیتی $|\mathcal{V}| = N$ و $\mathcal{E} \subseteq \mathcal{V} \times \mathcal{V}$ مجموعه یال‌های مشاهده‌شده است. ماتریس مجاورت $A \in \{0, 1\}^{N \times N}$ به‌گونه‌ای تعریف می‌شود که $A_{uv} = 1$ بیانگر وجود برهم‌کنش میان گره u و گره v است.

هدف، یادگیری تابع نگاشت پارامتری زیر است:

$$f_\theta : \mathcal{V} \times \mathcal{V} \rightarrow [0, 1], \quad \hat{y}_{uv} = f_\theta(u, v \mid G) \quad (1-1)$$

مدل‌سازی این مسئله روی گراف‌های زیستی با سه چالش ساختاری مواجه است:

چالش اول - تنک بودن شدید گراف: نسبت یال‌های شناخته‌شده به کل جفت‌های ممکن بسیار ناچیز است ($|\mathcal{E}| \ll N^2$). مدل باید در غیاب بخش عمده اتصالات، روابط پنهان را تعمیم دهد.

چالش دوم - توزیع دم‌سنگین درجه گره‌ها: تعداد اندکی گره پرتراکم (هاب) و انبوهی گره کم‌ارتباط وجود دارد [۱]. این توزیع نامتقارن می‌تواند مدل‌های ساده را به سمت بهره‌برداری از محبوبیت درجه (Degree Exploitation) سوق دهد.

چالش سوم - دوگانگی ساختاری گراف‌های همگن و دوقطبی: در شبکه‌های همگن (مانند DDI و PPI)، تمام گره‌ها از یک نوع هستند. در شبکه‌های دوقطبی (مانند DTI و GDI)، گره‌ها به دو دسته مجزا افراز می‌شوند ($\mathcal{V} = \mathcal{V}_1 \cup \mathcal{V}_2$) و هر یال الزاماً یک گره از $\mathcal{V}_1$ را به گره‌ای از $\mathcal{V}_2$ متصل می‌کند. در این ساختار، مسیرهای با طول زوج صرفاً گره‌های هم‌نوع را به یکدیگر وصل می‌کنند و اولین مسیر بازگشت به موجودیت مخالف، از طول فرد (A^3) خواهد بود. این ویژگی هندسی، پیامدهای مهمی برای طراحی عملگرهای پرسش توپولوژیک دارد که در فصل دوم به تفصیل اثبات خواهد شد.

^{۱۲} یادگیری بازنمایی روی گراف (Graph Representation Learning).

^{۱۳} پیش‌بینی پیوند (Link Prediction).

۱-۳ مدل مرجع و محدودیت‌های شناسایی شده

با ظهور شبکه‌های عصبی گراف^{۱۴}، به‌ویژه شبکه‌های پیچشی گراف^{۱۵} [۹]، پیشرفت‌های قابل توجهی در استخراج بازنمایی‌های برداری گره‌ها حاصل شد. مدل‌های استاندارد پیام‌ها را صرفاً در امتداد یال‌های مستقیم (۱-گام) عبور می‌دهند:

$$H^{(l+1)} = \sigma \left(\tilde{D}^{-1/2} \tilde{A} \tilde{D}^{-1/2} H^{(l)} W^{(l)} \right) \quad (۱-۲)$$

در سال ۲۰۲۰، هوانگ و همکاران مدلی تحت عنوان SkipGNN معرفی کردند [۷]. ایده محوری این مدل، تزریق «شباهت پرشی» از طریق ساخت گراف پرش ۲-گام بود:

$$A_s = \text{sign}(AA^T) \quad (۱-۳)$$

SkipGNN پیام‌ها را به‌صورت همزمان روی گراف اصلی A و گراف پرش A_s عبور داده و با دیکودر خطی جفت‌ها را امتیازدهی می‌کرد. این مدل با گزارش AUPRC به میزان 0.928 روی دیتاست DTI، عملکرد قابل توجهی نسبت به روش‌های پیشین گزارش کرد.

بازبینی دقیق تئوریک و تجربی در این پژوهش، چهار محدودیت ساختاری و روش‌شناختی در SkipGNN شناسایی کرد:

محدودیت اول - بن‌بست هندسی در گراف‌های دوقطبی: در گراف‌های دوقطبی DTI و GDI، ماتریس A^2 ساختاری بلوکی-قطری دارد. کانال پرش SkipGNN پیام‌ها را فقط بین گره‌های هم‌نوع (دارو-دارو یا ژن-ژن) ردوبدل می‌کند و اطلاعاتی درباره تارگت‌های کاندید از نوع مخالف انتقال نمی‌دهد. اثبات کامل این موضوع در بخش ۲-۴-۱ ارائه می‌شود.

محدودیت دوم - حذف اطلاعات چگالی بر اثر باینری‌سازی: استفاده از تابع sign در ساخت گراف پرش، تمایز میان جفت‌هایی با تعداد متفاوت همسایه مشترک را از بین می‌برد. جفتی با ۵۰ همسایه مشترک و جفتی با ۱ همسایه مشترک، وزن یکسانی (1.0) دریافت می‌کنند.

محدودیت سوم - تنگنای ظرفیت دیکودر: دیکودر SkipGNN صرفاً یک لایه خطی روی الحاق بردارها $[E_u \parallel E_v]$ است. این دیکودر فاقد مولفه‌های تعاملی ضربی و فاصله‌ای لازم برای بازنمایی برهم‌کنش‌های بیوشیمیایی متقارن است.

^{۱۴} شبکه‌های عصبی گراف (Graph Neural Networks).

^{۱۵} شبکه‌های پیچشی گراف (Graph Convolutional Networks).

محدودیت چهارم - سوگیری ساختاری در پروتکل ارزیابی: پروتکل ارزیابی مقاله مرجع، جفت‌های منفی را به صورت تصادفی و یکنواخت انتخاب می‌کرد. با توجه به توزیع دم‌سنگین درجه در گراف‌های زیستی، بخش عمده منفی‌های تصادفی از گره‌های کم‌درجه تشکیل می‌شوند. این امر تمایز یال‌های واقعی از منفی‌ها را به طور مصنوعی ساده می‌کند و ارزیابی قدرت تعمیم ساختاری مدل را دشوار می‌سازد. شواهد تجربی این پژوهش (فصل پنجم) نشان می‌دهد که عملکرد SkipGNN در آزمون یکنواخت (0.929 در DTI) به طور قابل توجهی بالاتر از عملکرد آن در آزمون با منفی‌های هم‌درجه (0.695) است. این الگو با یافته‌های لی و همکاران [۱۱] درباره محدودیت بنچمارک‌های مبتنی بر منفی‌های تصادفی هم‌راستا است.

۴-۱ پرسش‌ها و فرضیات پژوهش

این پروژه حول پنج پرسش پژوهشی و فرضیات متناظر شکل گرفته است:

پرسش اول (RQ1) - چگالی توپولوژیک پرش: آیا باینری‌سازی گراف پرش توسط عملگر sign موجب حذف اطلاعات شدت تعاملات می‌شود؟

فرضیه ۱ ($H1$): جایگزینی ماتریس باینری با ماتریس پیوسته تخصیص منابع [۲۱] به فرم $W = AD^{-1}A^T$ ، تمایز میان جفت‌های دارای مسیرهای غنی و ضعیف را حفظ کرده و از اشباع گرادیان در گره‌های هاب جلوگیری می‌کند.

پرسش دوم (RQ2) - دوگانگی ساختار دوقطبی: چگونه می‌توان در گراف‌های دوقطبی، پل اطلاعاتی میان موجودیت‌های ناهم‌نوع برقرار کرد؟

فرضیه ۲ ($H2$): تزریق صریح مسیرهای بازگشت ۳-گام به فرم $W_3 = W_2 D^{-1} A$ به عنوان کانال پیام‌رسانی، بن‌بست هندسی گام‌های زوج را جبران می‌نماید.

پرسش سوم (RQ3) - ظرفیت دیکودر: آیا دیکودرهای خطی مبتنی بر الحاق ساده در تفکیک منفی‌های سخت ناتوانند؟

فرضیه ۳ ($H3$): استفاده از دیکودر تانسوری تعاملی ۴-گانه متشکل از الحاق، ضرب هادامارد و تفاضل قدرمطلق $[E_u \parallel E_v \parallel E_u \odot E_v \parallel |E_u - E_v|]$ همراه با نرمال‌سازی دسته‌ای^{۱۶} [۸]، تقارن و غیرخطی بودن تعاملات را بازنمایی کرده و دقت تفکیک را بهبود می‌بخشد.

پرسش چهارم (RQ4) - تنظیم‌سازی فضا و پایداری بازنمایی: چگونه می‌توان از فروپاشی بازنمایی^{۱۷} و بیش‌برازش بر گره‌های هاب جلوگیری کرد؟

فرضیه ۴ ($H4$): اعمال قید خودنظارتی مقابله‌ای متقارن (InfoNCE) میان نمای گراف اصلی و نمای

^{۱۶} نرمال‌سازی دسته‌ای (Batch Normalization).

^{۱۷} فروپاشی بازنمایی (Representation Collapse): پدیده‌ای که در آن امبدینگ‌های گره‌های مختلف به یک بردار یکسان همگرا می‌شوند.

گراف پرش، خاصیت یکنواختی در فضای بازنمایی^{۱۸} [۱۹] را ارتقا می‌دهد.

پرسش پنجم (RQ5) - اعتبار پروتکل ارزیابی: آیا عملکرد گزارش‌شده در معیارهای یکنواخت، بازتاب‌دهنده قدرت تعمیم ساختاری مدل است؟

فرضیه ۵ (H5): ارزیابی مدل‌ها روی بانک آزمون با منفی‌های هم‌درجه، سوگیری محبوبیت گره‌ها را حذف کرده و معیاری پایاتر برای سنجش تعمیم ساختاری ارائه می‌دهد.

۵-۱ مدل‌های پیشنهادی و نوآوری‌های پژوهش

برای پاسخ به پرسش‌های فوق، چهار مدل در چارچوب یک پایپ‌لاین یکپارچه طراحی و پیاده‌سازی شدند. هر یک از این مدل‌ها بر بُعد مشخصی از محدودیت‌های شناسایی‌شده تمرکز دارد:

مدل ۱ - AMS-SkipGNN (Attentive Multi-Scale SkipGNN): مدل اصلی پژوهش که سه محدودیت اول را به‌طور همزمان هدف قرار می‌دهد. این مدل پرسش باینری را با پرسش پیوسته تخصیص منابع جایگزین می‌کند، جمع ساده لایه‌ای را با واحدهای گیتینگ تطبیقی باقی‌مانده تعویض می‌نماید و دیکودر خطی را با دیکودر تانسوری تعاملی ۴گانه جایگزین می‌سازد.

مدل ۲ - SkipGATv2: این مدل محدودیت انتشار ثابت لاپلاسی را هدف قرار می‌دهد. با جایگزینی کانولوشن ثابت با مکانیزم توجه پویا لبه‌ای [۲]، شبکه قادر است یال‌های کم‌اطلاع را به‌صورت خودکار کم‌اهمیت کند. این مدل در گراف همگن PPI عملکرد قابل‌توجهی ثبت کرده و در بخش ۵-۲ تحلیل می‌شود.

مدل ۳ - ThreeHopSkipGNN: این مدل به‌طور اختصاصی بن‌بست هندسی گراف‌های دوقطبی (محدودیت اول) را هدف قرار می‌دهد. با ادغام موازی سه کانال ۱-گام، ۲-گام هم‌نوع و ۳-گام دوقطبی و ترکیب آن‌ها از طریق گیت سافت‌مکس یادگیرنده، دسترسی مستقیم انکودر به اهداف کاندید در گراف‌های دوقطبی فراهم می‌شود.

مدل ۴ - ContrastiveSkipGNN: این مدل محدودیت چهارم (پایداری فضای بازنمایی) را هدف قرار می‌دهد. با ترکیب یادگیری بانظارت پیش‌بینی پیوند و قید خودنظارتی مقابله‌ای متقارن، از انحراف و چسبندگی امبدینگ‌های هاب جلوگیری می‌شود.

نکته شفاف‌سازی: مدل AMS عمیق‌ترین اعتبارسنجی ساختاری (نردبان ابلیشن کامل، بخش ۴-۷) را در میان چهار مدل دارد و در دیتاست DDI به‌وضوح برترین مدل عصبی است. با این حال، از نظر امتیاز خام Hard AUPRC، در سه دیتاست دیگر (GDI، PPI، DTI) با SkipGATv2 هم‌سطح یا در محدوده انحراف معیار آن قرار دارد. مقایسه کامل و دقیق آماری در فصل پنجم و بحث در فصل ششم ارائه می‌شود.

^{۱۸} یکنواختی در فضای بازنمایی (Uniformity).

۱-۵-۱ نوآوری‌های روش‌شناختی

علاوه بر نوآوری‌های معماری، دو کمک روش‌شناختی در این پژوهش ارائه شده است: پروتکل ارزیابی دوگانه (Dual-Bank Protocol): ارزیابی همزمان بر روی بانک یکنواخت (برای بازتولید شرایط مقایسه با مقاله مرجع) و بانک سخت آگاه از نوع موجودیت با افراز چارک‌های درجه‌ای. پایپ‌لاین بدون نشت ترنسداکتیو: جداسازی کامل ماتریس مجاورت آموزشی از یال‌های اعتبارسنجی و آزمون، انتخاب آستانه بهینه (T^*) صرفاً روی داده‌های اعتبارسنجی و انجماد آن روی آزمون^{۱۹}، و اصلاح ناسازگاری‌های فرمت تنک/متراکم در کد مرجع.

۱-۵-۲ انتخاب آگاهانه ویژگی‌های ورودی

در این پژوهش، ویژگی‌های ورودی گره‌ها به بردارهای هویت تنک (One-Hot) محدود شده‌اند. این انتخاب یک تصمیم روش‌شناختی آگاهانه است: هدف اصلی، سنجش ظرفیت خالص معماری‌های پیام‌رسانی در کشف الگوهای توپولوژیک پیوند است، نه ارزیابی قدرت مدل‌های زبانی پیش‌آموزش‌دیده در پردازش ویژگی‌های بیوشیمیایی. افزودن ویژگی‌های غنی (مانند اثرانگشت مورگان یا امبدینگ‌های ESM-2) می‌تواند اثر معماری را با اثر ویژگی‌ها مخلوط کند و تفکیک سهم هر یک را دشوار سازد. این محدودیت به‌صراحت در فصل ششم به‌عنوان مسیر کار آینده ذکر شده است.

۱-۶ دستاوردهای عددی شاخص

نتایج تجربی کامل در فصل پنجم ارائه می‌شود. در اینجا، خلاصه‌ای از بهبودهای کلیدی نسبت به مدل مرجع SkipGNN در آزمون سخت (Hard AUPRC) گزارش می‌شود. مقادیر به فرم $\text{Mean} \pm \text{SD}$ در میان ۳ سید هستند. بهبود مطلق به واحد درصد (percentage points) بیان شده است:

جدول ۱-۱: بهبود مطلق نسبت به SkipGNN در Hard AUPRC (واحد درصد)

وضعیت آماری	بهبود مطلق	مدل‌های پیشنهادی برتر	SkipGNN	دیتاست
برتری بدون هم‌پوشانی بازه‌ها	+0.188	AMS: 0.912 ± 0.003	0.724 ± 0.005	DDI
برتری بدون هم‌پوشانی بازه‌ها	+0.156	SkipGATv2: 0.778 ± 0.006	0.622 ± 0.012	PPI
برتری مرزی (بازه‌ها به‌سختی جدا)	+0.117	SkipGATv2: 0.837 ± 0.003	0.720 ± 0.012	GDI
هم‌سطح آماری (بازه‌های هم‌پوشان)	+0.10 تا +0.11	AMS و SkipGATv2 و 3-hop هم‌سطح	0.695 ± 0.012	DTI

توضیح: در دیتاست DTI، سه مدل پیشنهادی - AMS (0.798 ± 0.011)، SkipGATv2 (0.804 ± 0.005) و 3-hop (0.803 ± 0.015) - بازه‌های انحراف معیار هم‌پوشانی دارند و طبق معیار عدم هم‌پوشانی بازه‌ها (بخش ۵-۱-۵)، از نظر آماری قابل تفکیک نیستند.

شایان ذکر است که در دیتاست GDI، هوریستیک تحلیلی تخصیص منابع (بدون پارامتر یادگیرنده) به

^{۱۹} جلوگیری از نشت اطلاعات در انتخاب آستانه (Threshold Leakage Prevention).

امتیاز 0.842 ± 0.001 دست یافته که بالاتر از تمام مدل‌های عصبی است. این یافته به‌عنوان یک بینش مهم درباره محدودیت‌های ذاتی مدل‌های عصبی در گراف‌های بسیار بزرگ و تنک با ویژگی‌های هویتی، در فصل ششم به تفصیل بحث می‌شود.

۷-۱ ساختار فصول گزارش

ادامه گزارش در پنج فصل به شرح زیر سازمان‌دهی شده است:

فصل دوم به مبانی نظری شبکه‌های عصبی گراف، پیش‌بینی پیوند و نقد ساختاری مدل مرجع SkipGNN اختصاص دارد. اثبات ریاضی بن‌بست بلوکی ماتریس A^2 در گراف‌های دوقطبی در این فصل ارائه می‌شود.

فصل سوم مشخصات چهار دیتاست، پایپ‌لاین بدون نشت داده، فرمولاسیون عملگرهای پرسش توپولوژیک و پروتکل ارزیابی دوگانه را تشریح می‌کند.

فصل چهارم فرمولاسیون ریاضی دقیق چهار مدل پیشنهادی (AMS، SkipGATv2، ThreeHop، Contrastive) و خطوط مبنا را ارائه می‌دهد.

فصل پنجم شامل پروتکل آموزش، ماتریس کامل نتایج عددی، تحلیل ده نمودار و بررسی فضاهای نهفته با t-SNE است.

فصل ششم به بحث، تبیین چرایی نتایج، تحلیل محدودیت‌ها و موارد شکست، پاسخ به پرسش‌های پژوهش و ترسیم مسیرهای آینده می‌پردازد.

فصل ۲

مبانی نظری، ادبیات موضوع و نقد ساختاری مدل مرجع

۲-۱ مبانی نظری یادگیری بازنمایی روی گراف

۲-۱-۱ تعاریف پایه و نمادگذاری ریاضی

یک شبکه تعاملی زیستی به صورت گراف بدون جهت $G = (\mathcal{V}, \mathcal{E})$ مدل سازی می شود:

-- مجموعه گره ها $\mathcal{V}$: موجودیت های بیولوژیکی با کاردینالیتی $|\mathcal{V}| = N$.

-- مجموعه یال ها $\mathcal{E}$: برهم کنش های تجربی مشاهده شده با تعداد $|\mathcal{E}| = M$.

-- ماتریس مجاورت $A \in \{0, 1\}^{N \times N}$: ماتریسی متقارن که $A_{uv} = 1$ در صورت وجود یال $(u, v) \in \mathcal{E}$.

-- ماتریس درجه $D \in \mathbb{R}^{N \times N}$: ماتریس قطری با عناصر $D_{uu} = d_u = \sum_v A_{uv}$.

-- ماتریس ویژگی های ورودی $X \in \mathbb{R}^{N \times d_{in}}$: در این پژوهش، $X = I_N$ (ماتریس هویت تنک) انتخاب شده است (بخش ۱-۵-۲).

۲-۱-۲ پارادایم انتشار پیام (Message Passing)

اکثریت قاطع شبکه های عصبی گراف مدرن از چارچوب شبکه های عصبی پیام رسان^۱ [۵] پیروی می کنند. در این رویکرد، بازنمایی هر گره v در لایه $(l + 1)$ از طریق چرخه «تجمیع» و «به روز رسانی» محاسبه می شود:

$$m_v^{(l+1)} = \text{AGG}^{(l+1)} \left(\left\{ \text{MSG}^{(l+1)} \left(h_u^{(l)}, h_v^{(l)} \right) : u \in \mathcal{N}(v) \right\} \right) \quad (2-1)$$

$$h_v^{(l+1)} = \text{UPDATE}^{(l+1)} \left(h_v^{(l)}, m_v^{(l+1)} \right) \quad (2-2)$$

^۱ شبکه های عصبی پیام رسان (Message Passing Neural Networks).

۲-۱-۳ شبکه‌های پیچشی گراف و نرمال‌سازی لاپلاسی

کیف و ولینگ [۹] معماری GCN را بر پایه نرمال‌سازی متقارن لاپلاسی فرموله کردند:

$$\tilde{A} = A + I_N, \quad \tilde{D}_{uu} = d_u + 1 \quad (۲-۳)$$

$$F = \tilde{D}^{-1/2} \tilde{A} \tilde{D}^{-1/2} \quad (۲-۴)$$

$$H^{(l+1)} = \sigma \left(F H^{(l)} W^{(l)} \right) \quad (۲-۵)$$

در پیاده‌سازی این پژوهش (تابع `laplacian_normalize` در `src/data/normalization.py`), برای گره‌های منزوی به‌جای افزودن ϵ مصنوعی، مقدار صفر منظور می‌شود:

$$(D^{-1/2})_{ii} = \begin{cases} d_i^{-0.5} & \text{if } d_i > 0 \\ 0 & \text{otherwise} \end{cases} \quad (۲-۶)$$

تقویت مصنوعی گره‌های منزوی جلوگیری می‌کند و در آزمون واحد `test_laplacian_isolated_nodes_are_zero` اعتبارسنجی شده است.

۲-۱-۴ چالش بیش‌هموارسازی

با افزایش عمق لایه‌ها، عملگر انتشار F به‌عنوان فیلتر پایین‌گذر عمل کرده و بازنمایی گره‌ها به سمت همگرایی میل می‌کند [۱۲]:

$$\lim_{l \rightarrow \infty} H^{(l)} \propto \mathbf{1} \cdot \pi^T \quad (۲-۷)$$

^۲ بیش‌هموارسازی (Over-smoothing).

در شبکه‌های زیستی تنک با قطر کوچک $[20]^3$ ، این پدیده تشدید می‌شود. این چالش یکی از انگیزه‌های طراحی عملگرهای پرش توپولوژیک در این پژوهش است.

۲-۲ پیش‌بینی پیوند و خطوط مبنای هوریستیک

۲-۲-۱ صورت‌بندی مسئله

اگر امبدینگ نهایی گره‌ها $E = H^{(L)} \in \mathbb{R}^{N \times d}$ باشد، احتمال یال میان u و v توسط دیکودر تخمین زده می‌شود:

$$\hat{y}_{uv} = \text{Decoder}(E_u, E_v) \quad (2-8)$$

۲-۲-۲ شاخص‌های هوریستیک غیرپارامتری

پیش از GNNها، پیش‌بینی پیوند با شاخص‌های ساختاری انجام می‌گرفت. جدول ۱-۲ چهار شاخص اصلی را خلاصه می‌کند:

جدول ۱-۲: فرمولاسیون شاخص‌های هوریستیک کلاسیک

شاخص	فرمول	ویژگی
همسایگان مشترک (CN)	$ \mathcal{N}(u) \cap \mathcal{N}(v) $	شمارش ساده بدون جریمه درجه
ضریب جاکارد	$\frac{ \mathcal{N}(u) \cap \mathcal{N}(v) }{ \mathcal{N}(u) \cup \mathcal{N}(v) }$	نرمال‌سازی با اجتماع
آدامیک-آدار (AA)	$\sum_k \log(\max(2, d_k))$	جریمه لگاریتمی هاب‌ها
تخصیص منابع (RA)	$\sum_k \frac{1}{\max(1, d_k)}$	جریمه خطی هاب‌ها

شاخص تخصیص منابع [۲۱] در این پژوهش هم به‌عنوان عملگر پرش پیوسته (بخش ۳-۳-۲) و هم به‌عنوان خط مبنای غیرپارامتری (`src/models/heuristics.py`) به‌کار رفته است. در گراف‌های همگن، امتیاز بر پایه همسایگان مشترک وزن‌دار محاسبه می‌شود. در گراف‌های دوقطبی، از آنجا که همسایگان مشترک ۱-گام تهی هستند، از ضرب ماتریسی ۳-گام استفاده می‌شود:

$$\text{Score}(u, v) = (AD^{-1}A^TD^{-1}A)_{uv} \quad (2-9)$$

این فرمولاسیون در تابع `_bipartite_three_walk_scores` پیاده‌سازی شده و در آزمون `test_bipartite_heuristics_are_nonzero` صحت‌سنجی گردیده است.

^۳ خاصیت جهان کوچک (Small-World Property).

۲-۳ تشریح مدل مرجع SkipGNN

مدل SkipGNN [۷] با فرض «شبهات پرشی» معرفی شد: موجودیت‌هایی که مستقیماً متصل نیستند اما همسایگان مشترک دارند، شبهات ساختاری دارند.

۲-۳-۱ ساخت گراف پرش باینری

$$A_s = \text{sign}(AA^T) \quad (2-10)$$

۲-۳-۲ معماری ادغام دوکاناله

لایه اول انکودر:

$$H^{(1)} = \text{ReLU}(FXW_o + F_sXW_{so}) \quad (2-11)$$

$$S^{(1)} = \text{ReLU}(F_sXW_s + FH^{(1)}W_{os}) \quad (2-12)$$

لایه دوم و تجميع نهایی:

$$E = F\hat{H}^{(1)}W_o^{(1)} + F_s\hat{S}^{(1)}W_{s2o}^{(1)} \quad (2-13)$$

۲-۳-۳ دیکودر خطی

$$\text{feat}_{uv} = [E_u \parallel E_v] \in \mathbb{R}^{2d_2} \quad (2-14)$$

$$\text{Logit}_{uv} = W_{d2} \cdot \text{ReLU}(W_{d1} \text{feat}_{uv} + b_{d1}) + b_{d2} \quad (2-2?)$$

این مدل در کد این پژوهش به صورت `SkipGNNBaseline` (src/models/skipgnn.py) بازپاده سازی شده است.

۲-۴ نقد ساختاری و ریاضی SkipGNN

تحلیل ریاضی و تجربی در این پژوهش، سه محدودیت بنیادین در معماری SkipGNN شناسایی کرده است.

۲-۴-۱ بن بست هندسی در گراف های دوقطبی (اثبات ریاضی)

قضیه: در گراف دوقطبی با افراز $\mathcal{V} = \mathcal{V}_1 \cup \mathcal{V}_2$ ، ماتریس A^2 ساختاری بلوکی-قطری دارد و بلوک های غیرقطری آن صفر هستند.

اثبات: ماتریس مجاورت گراف دوقطبی به فرم بلوکی زیر است:

$$A = \begin{bmatrix} \mathbf{0} & B \\ B^T & \mathbf{0} \end{bmatrix} \quad (2-2?)$$

محاسبه A^2 :

$$A^2 = \begin{bmatrix} \mathbf{0} & B \\ B^T & \mathbf{0} \end{bmatrix} \begin{bmatrix} \mathbf{0} & B \\ B^T & \mathbf{0} \end{bmatrix} = \begin{bmatrix} BB^T & \mathbf{0} \\ \mathbf{0} & B^T B \end{bmatrix} \quad (2-2?)$$

بلوک های غیرقطری صفر مطلق هستند. بنابراین، گراف پرش $A_s = \text{sign}(A^2)$ هیچ یالی میان $\mathcal{V}_1$ و $\mathcal{V}_2$ ایجاد نمی کند. ■

نتیجه: در مسئله پیش بینی DTI، کانال پرش SkipGNN پیام ها را فقط میان دارو-دارو و پروتئین-پروتئین منتقل می کند و اطلاعاتی درباره تارگت های کاندید از نوع مخالف ارائه نمی دهد.

مسیر ۳-گام به عنوان اولین پل: محاسبه A^3 نشان می دهد که بلوک های غیرقطری فعال می شوند:

$$A^3 = \begin{bmatrix} \mathbf{0} & BB^T B \\ B^T BB^T & \mathbf{0} \end{bmatrix} \quad (2-2?)$$

بنابراین، مسیر $p \rightarrow d' \rightarrow p' \rightarrow d$ (دارو $\leftarrow$ پروتئین واسط $\leftarrow$ داروی واسط $\leftarrow$ پروتئین هدف) اولین مسیر توپولوژیک غیرمستقیم برای دسترسی به تارگت کاندید است. این بینش، انگیزه طراحی عملگر ۳-گام در مدل‌های ThreeHopSkipGNN و هوریستیک دوقطبی است.

۲-۴-۲ حذف اطلاعات چگالی بر اثر باینری سازی

عملگر sign در معادله (۲-۱۰)، تمایز میان جفت‌هایی با تعداد متفاوت همسایه مشترک را حذف می‌کند:

$$(A_s)_{uv} = \text{sign}(|\mathcal{N}(u) \cap \mathcal{N}(v)|) \in \{0, 1\} \quad (2-2?)$$

جفتی با ۵۰ همسایه مشترک و جفتی با ۱ همسایه مشترک، وزن یکسانی دریافت می‌کنند. در گراف متراکم DDI (میانگین درجه ۶۴)، این باینری سازی گراف پرش را به گرافی نزدیک به کامل تبدیل می‌کند. راه حل پیشنهادی: عملگر تخصیص منابع (بخش ۳-۳-۲):

$$W_2 = AD^{-1}A^T, \quad (W_2)_{uv} = \sum_{k \in \mathcal{N}(u) \cap \mathcal{N}(v)} \frac{1}{d_k} \quad (2-20)$$

۲-۴-۳ تنگنای ظرفیت دیکودر خطی

دیکودر معادله (۲-۱۵) فاقد مؤلفه‌های تعاملی ضربی و فاصله‌ای است. در گراف‌های بدون جهت، تقارن پیش‌بینی ($\hat{y}_{uv} = \hat{y}_{vu}$) تضمین نمی‌شود.

راه حل پیشنهادی: دیکودر تانسوری ۴ گانه (بخش ۴-۲-۴):

$$Z_{uv} = [E_u \parallel E_v \parallel E_u \odot E_v \parallel |E_u - E_v|] \quad (2-21)$$

۲-۵ نقد روش شناختی پروتکل ارزیابی

۲-۵-۱ سوگیری درجه در نمونه برداری منفی یکنواخت

در پروتکل ارزیابی مقاله مرجع، منفی‌ها به صورت تصادفی یکنواخت انتخاب می‌شدند. با توجه به توزیع دم‌سنگین درجه در گراف‌های زیستی [۱]، بخش عمده منفی‌های تصادفی از گره‌های کم‌درجه تشکیل می‌شوند. شواهد تجربی این پژوهش (جدول ۳-۵) نشان می‌دهد که عملکرد SkipGNN در آزمون یکنواخت (0.929 در DTI) به طور قابل توجهی بالاتر از آزمون با منفی‌های هم‌درجه (0.695) است. این یافته با نقد لی و همکاران [۱۱] درباره محدودیت‌های بنچمارک‌های مبتنی بر منفی‌های تصادفی هم‌راستا است.

۲-۵-۲ ناسازگاری‌های پیاده‌سازی در کد مرجع

بازبینی کد رسمی SkipGNN [۶]، چند ناسازگاری نرم‌افزاری شناسایی کرد که در این پژوهش اصلاح شدند:

ناسازگاری اول - آستانه‌گذاری روی لاجیت خام: در تابع ارزیابی کد مرجع، شرط $\text{Logit} \geq 0.5$ اعمال می‌شد، معادل احتمال $\sigma(0.5) \approx 0.622$. این پروژه آستانه τ^* را صرفاً روی اعتبارسنجی و با پویش ۹۱ نقطه‌ای محاسبه می‌کند (src/eval/metrics.py).

ناسازگاری دوم - فرمت تنک/متراکم: در لودر DDI کد مرجع، ماتریس مجاورت به فرمت متراکم تبدیل می‌شد، در حالی که لایه GCN انتظار تنسور تنک داشت. این پروژه تمام ماتریس‌ها را در فرمت torch.sparse_coo_tensor کوالس شده نگه می‌دارد.

ناسازگاری سوم - نرمال‌سازی ویژگی‌ها: نرمال‌سازی سطری L_1 روی امبدینگ‌های Node2Vec (که شامل مقادیر منفی هستند) می‌توانست اعوجاج ایجاد کند. این پروژه از استانداردسازی ستونی Z-Score استفاده می‌کند.

۲-۶ جمع‌بندی: شکاف پژوهشی و ضرورت مدل‌های پیشنهادی

جدول ۲-۲ خلاصه‌ای از محدودیت‌های شناسایی شده و راه‌حل‌های ارائه شده در این پژوهش را نشان می‌دهد:

فصول بعدی به تشریح داده‌ها (فصل ۳)، فرمولاسیون ریاضی چهار مدل پیشنهادی (فصل ۴)، نتایج تجربی (فصل ۵) و بحث (فصل ۶) اختصاص دارند.

^۴ مخزن کد مرجع: github.com/kexinhuang12345/SkipGNN

جدول ۲-۲: مقایسه محدودیت‌های SkipGNN و راه‌حل‌های پیشنهادی

مؤلفه	وضعیت در SkipGNN	راه‌حل در این پژوهش
عملگر پرش	باینری $\text{sign}(AA^T)$	پیوسته تخصیص منابع $AD^{-1}A^T$
گراف دوقطبی	بن‌بست گام زوج A^2	مسیرهای ۳-گام $(W_2D^{-1}A)$
ادغام لایه‌ای	جمع ثابت	گیتینگ تطبیقی سیگموئیدی
دیکودر	الحاق خطی $[E_u \parallel E_v]$	تانسوری ۴-گانه + BatchNorm
پایداری فضا	فاقد قید	زبان متقارن InfoNCE
پروتکل ارزیابی	یکنواخت	دوگانه (یکنواخت + سخت هم‌درجه)

فصل ۳

داده‌ها، توپولوژی گراف‌های زیستی و پروتکل ارزیابی دوگانه

۳-۱ مجموعه‌های داده معیار و تحلیل ساختاری آن‌ها

برای ارزیابی مدل‌های پیشنهادی و مقایسه با خطوط مبنا، از چهار پایگاه داده استاندارد زیست‌مولکولی استفاده شده است. این داده‌ها طیف کاملی از ساختارهای شبکه‌ای را پوشش می‌دهند: گراف‌های همگن و دوقطبی، گراف‌های متراکم و تنک، و مقیاس‌های مختلف از ۱,۵۱۴ تا ۱۹,۷۸۳ گره. تمامی داده‌ها از پوشه fold1 مخزن رسمی SkipGNN [۷] استخراج شده‌اند و بدون هیچ تغییری در تقسیم‌بندی استفاده می‌شوند.

جدول ۳-۱: مشخصات آماری و توپولوژیک چهار بنچمارک استاندارد

مجموعه داده	نوع شبکه	نود مبدا	نود مقصد	کل نودها (N)	یال آموزش	یال اعتبارسنجی	یال آزمون	میانگین درجه
DDI	همگن	۱,۵۱۴ (دارو)	-	۱,۵۱۴	۶۷,۹۱۹	۹,۷۰۳	۱۹,۴۰۶	۰.۹۶۴
PPI	همگن	۵,۶۰۴ (پروتئین)	-	۵,۶۰۴	۳۲,۶۵۱	۴,۶۶۴	۹,۳۲۹	۳۲.۸
DTI	دوقطبی	۵,۰۱۸ (دارو)	۲,۳۲۵ (پروتئین)	۷,۳۴۳	۲۱,۱۹۴	۳,۰۲۸	۶,۰۵۶	۱۲.۴
GDI	دوقطبی	۹,۴۱۳ (ژن)	۱۰,۳۷۰ (بیماری)	۱۹,۷۸۳	۱۱۴,۴۴۵	۱۶,۳۴۹	۳۲,۶۹۸	۲۶.۸

۳-۱-۱ پایگاه داده برهم‌کنش دارو-دارو (BioSNAP-DDI)

این شبکه شامل تداخلات فارماکوکینتیکی و فارماکودینامیکی بین داروهای تأییدشده توسط FDA است که از پایگاه داده DrugBank استخراج و توسط مجموعه BioSNAP استنفورد توزیع شده است [۱۸].

ویژگی‌های ساختاری:

- گراف همگن متقارن با $N = 1,514$ دارو و 67,919 یال آموزشی مثبت.
- میانگین درجه بسیار بالا ($\bar{d} = 64.09$): متراکم‌ترین گراف در بنچمارک.
- ساختار جوامع هم‌پوشان غالب است. در چنین ساختاری، مسیرهای ۲-گام هم‌نوع دارای غنای اطلاعاتی فراوانی هستند.

۳-۱-۲ پایگاه داده برهم‌کنش پروتئین-پروتئین (HuRI-PPI)

این تراکتوم مرجع پروتئینی انسان [۱۴] که از طریق آزمایش‌های غربال‌گری دو رگه‌ای مخمری با توان بالا به دست آمده است.

ویژگی‌های ساختاری:

-- گراف همگن متقارن با $N = 5,604$ پروتئین و 32,651 یال آموزشی مثبت.

-- میانگین درجه تنک ($\bar{d} = 8.32$).

-- ساختار مدولار زیستی با ضریب خوشه‌بندی محلی بالا، بازتاب‌دهنده کمپلکس‌های پروتئینی سلولی.

۳-۱-۳ پایگاه داده برهم‌کنش دارو-هدف (BioSNAP-DTI)

تعاملات مهاری و اتصال مولکول‌های دارو به پروتئین‌های هدف انسانی، استخراج‌شده از داده‌های ChG-DrugBank و Miner.

ویژگی‌های ساختاری:

-- گراف دوقطبی با $N = 7,343$ موجودیت: $N_{\text{drug}} = 5,018$ دارو ($\mathcal{V}_1$) و $N_{\text{protein}} = 2,325$ پروتئین ($\mathcal{V}_2$).

-- 21,194 یال آموزشی مثبت با میانگین درجه بسیار تنک ($\bar{d} = 4.12$).

-- نسبت داروها به پروتئین‌ها حدود 2.15 است.

۳-۱-۴ پایگاه داده برهم‌کنش ژن-بیماری (DisGeNET-GDI)

پایگاه داده جامع DisGeNET [۱۶] که همبستگی‌های تجربی میان ژن‌های انسانی و فنوتیپ‌های بیماری را بر پایه شواهد بالینی و ژنتیکی گردآوری می‌کند.

ویژگی‌های ساختاری:

-- گراف دوقطبی کلان با $N = 19,783$ موجودیت: $N_{\text{gene}} = 9,413$ ژن و $N_{\text{disease}} = 10,370$ بیماری.

-- 114,445 یال آموزشی مثبت با میانگین درجه 8.26.

-- بزرگ‌ترین چالش محاسباتی و حافظه‌ای را به دلیل ابعاد ماتریس مجاورت ایجاد می‌کند.

۳-۲ پایپ‌لاین بدون نشت داده (Leak-Free Pipeline)

یکی از مهم‌ترین نیازمندی‌های روش‌شناختی در پیش‌بینی پیوند، تضمین عدم نشت اطلاعات از مجموعه‌های اعتبارسنجی و آزمون به ساختار گراف آموزشی است. پایپ‌لاین پیاده‌سازی‌شده در تابع `load_dataset_splits` (ماژول `src/data/loader.py`) این تضمین را در پنج مرحله فراهم می‌کند:

مرحله ۱ - نگاشت شناسه‌ها: رشته‌های شناسایی موجودیت‌ها به اندیس‌های صحیح پیوسته نگاشت

می‌شوند. در گراف‌های دوقطبی، تابع `build_idx_map` با استفاده از هیوریستیک نوع‌شناسی (پیشوند DB برای داروها در DTI، شناسه عددی برای ژن‌ها در GDI)، منابع و اهداف را به‌طور قطعی تفکیک می‌کند. در صورت انحراف بیش از یک واحد از تعداد مورد انتظار منابع، لودر خطا صادر می‌کند.

مرحله ۲ - جهت‌یابی دوقطبی: در گراف‌های DTI و GDI، تابع `_orient_bipartite` تضمین می‌کند که ستون اول همواره مبدا و ستون دوم همواره مقصد باشد:

$$\text{if } u \geq N_{\text{src}} \wedge v < N_{\text{src}} \implies \text{swap}(u, v) \quad (3-1)$$

مرحله ۳ - ساخت ماتریس مجاورت آموزشی: ماتریس A_{train} صرفاً از یال‌های مثبت آموزشی ساخته می‌شود:

$$\mathcal{E}_{\text{train}} = \{(u, v) \in \mathcal{D}_{\text{train}} : y_{uv} = 1\} \quad (3-2)$$

$$A_{\text{train}} = \text{SymmetricClosure}(\mathcal{E}_{\text{train}}) \quad (3-3)$$

مرحله ۴ - ساخت عملگرهای پرش: تمام ماتریس‌های پرش (W_3, W_2, F_s) مستقیماً از A_{train} ساخته می‌شوند. هیچ ردی از یال‌های اعتبارسنجی یا آزمون در آن‌ها وجود ندارد.

مرحله ۵ - ثبت مثبت‌های شناخته‌شده: یال‌های مثبت اعتبارسنجی و آزمون در یک مجموعه هش (`known_positives`) نگهداری می‌شوند تا در مرحله نمونه‌برداری منفی، از انتخاب تصادفی یال‌های واقعی جلوگیری شود. این یال‌ها هرگز وارد A_{train} نمی‌شوند. صحت این تضمین در آزمون‌های واحد `test_dti_bipartite_ranges` و `test_ddi_shapes_and_no_leakage` اعتبارسنجی شده است.

۳-۲-۱ انتخاب آگاهانه ویژگی‌های ورودی

در این پژوهش، ویژگی‌های ورودی گره‌ها به ماتریس هویت تنک ($X = I_N$) محدود شده‌اند. این یک تصمیم روش‌شناختی آگاهانه است:

هدف: سنجش ظرفیت خالص معماری‌های پیام‌رسانی در کشف الگوهای توپولوژیک پیوند، بدون دخالت

ویژگی‌های بیوشیمیایی.

توجیه: افزودن ویژگی‌های غنی (مانند اثرانگشت مورگان یا امبدینگ‌های ESM-2) می‌تواند اثر معماری را با اثر ویژگی‌ها مخلوط کند و تفکیک سهم هر یک را دشوار سازد. این محدودیت به‌صراحت در فصل ششم به‌عنوان مسیر کار آینده ذکر شده است.

۳-۲-۲ ساخت تنسورهای تنک کوالس‌شده

تمام ماتریس‌های مجاورت ابتدا به فرمت تنک فشرده سطری (`scipy.sparse.csr_matrix`) ساخته شده و پس از اعمال عملگرهای ریاضی، به فرمت مختصات تنک ۳۲ بیتی تبدیل می‌شوند. تابع `scipy_to_torch_sparse` تنسور تنک ادغام‌شده (`torch.sparse_coo_tensor().coalesce()`) را مستقیماً روی حافظه GPU بارگذاری می‌کند.

۳-۳ عملگرهای پرش توپولوژیک (Topological Skip Operators)

سه دسته عملگر پرش توپولوژیک به صورت ماتریس‌های تنک بهینه‌شده طراحی و پیاده‌سازی شده‌اند (ماژول `src/data/normalization.py`):

۳-۳-۱ عملگر پرش باینری بدون سلف‌لوپ (Binary Skip)

بازتولید ساختار پرش مقاله مرجع [۷] با یک اصلاح ساختاری: قطر اصلی صراحتاً صفر می‌شود:

$$A_s^{\text{bin}} = \text{sign}(A_{\text{train}} \cdot A_{\text{train}}^T), \quad (A_s^{\text{bin}})_{uu} = 0 \quad \forall u \quad (3-4)$$

۳-۳-۲ عملگر پرش پیوسته تخصیص منابع (Resource Allocation Skip)

برای حفظ اطلاعات شدت پیوند و چگالی همسایگان مشترک، عملگر تخصیص منابع [۲۱] جایگزین عملگر علامت می‌شود:

$$(D^{-1})_{kk} = \begin{cases} \frac{1}{d_k} & \text{if } d_k > 0 \\ 0 & \text{if } d_k = 0 \end{cases} \quad (3-5)$$

$$W_2 = A_{\text{train}} \cdot D^{-1} \cdot A_{\text{train}}^T, \quad (W_2)_{uu} = 0 \quad \forall u \quad (3-6)$$

عنصر $(W_2)_{uv}$ بیانگر مجموع وزن‌های اشتراک میان دو گره u و v است:

$$(W_2)_{uv} = \sum_{k \in \mathcal{N}(u) \cap \mathcal{N}(v)} \frac{1}{d_k} \quad (3-7)$$

تحلیل رفتار: اگر دو دارو از طریق یک پروتئین اختصاصی با درجه پایین ($d_k = 2$) متصل باشند، وزن پرش 0.5 خواهد بود؛ در حالی که اگر از طریق یک پروتئین هاب غیراختصاصی ($d_k = 100$) متصل باشند، وزن پرش به 0.01 کاهش می‌یابد. این فرمولاسیون به طور خودکار نویز هاب‌ها را مهار می‌کند. **نکته پیاده‌سازی:** در کد `(build_weighted_skip)`، برای جلوگیری از تقسیم بر صفر، از $\max(1, d_k)$ استفاده شده است. این معادل همان رفتار ریاضی معادله (3-5) است، زیرا گره‌های با درجه صفر در A_{train} هیچ همسایه‌ای ندارند و در مجموع ظاهر نمی‌شوند.

3-3-3 عملگر مسیر بازگشت 3-گام (Bipartite 3-Walk Return)

همان‌طور که در بخش 2-4-1 اثبات شد، در گراف‌های دوقطبی، ماتریس W_2 اتصالات درون‌نوعی را برقرار می‌کند. برای انتقال پیام به موجودیت هدف کاندید، یک گام انتشار اضافی لازم است:

$$W_3 = W_2 \cdot D^{-1} \cdot A_{\text{train}} \quad (3-8)$$

مفهوم زیستی: در گراف DTI، مقدار $(W_3)_{dp}$ نشان‌دهنده امتیاز انتقال پیام از داروی d به پروتئین p از طریق تمام مسیرهای طول 3 ($d \rightarrow p' \rightarrow d' \rightarrow p$) است.

3-3-4 نرمال‌سازی لاپلاسی متقارن ایمن (Safe Laplacian Normalization)

در پیاده‌سازی‌های رایج، برای جلوگیری از تقسیم بر صفر، مقدار کوچک ϵ اضافه می‌شود. اشکال ریاضی: اگر نودی ایزوله باشد ($d = 0$)، اضافه کردن $\epsilon = 10^{-5}$ باعث می‌شود مقدار نرمال‌شده $\approx \frac{1}{\sqrt{10^{-5}}}$ شود. 316

راهکار پیاده‌سازی شده (تابع `laplacian_normalize`):

$$(D^{-1/2})_{ii} = \begin{cases} d_i^{-0.5} & \text{if } d_i > 0 \\ 0 & \text{otherwise} \end{cases} \quad (3-9)$$

$$F = D^{-1/2} A D^{-1/2} \quad (3-10)$$

برای گراف اصلی، ابتدا سلفلوپ اضافه می‌شود $(A + I_N)$. برای گراف‌های پرش، بدون سلفلوپ محاسبه می‌گردد. این رفتار در آزمون واحد `test_laplacian_isolated_nodes_are_zero` اعتبارسنجی شده است.

جدول ۳-۲: خلاصه عملگرهای توپولوژیک و مدل‌های مصرف‌کننده

مدل‌های مصرف‌کننده	فرمولاسیون لاپلاسی	عملگر پایه	تنسور در کد
تمام مدل‌های عصبی	$\tilde{D}^{-1/2}(A + I)\tilde{D}^{-1/2}$	$A + I_N$	f_orig
SkipGNNBaseline	$\tilde{D}_s^{-1/2} A_s^{\text{bin}} \tilde{D}_s^{-1/2}$	$\text{sign}(AA^T) - \text{diag}$	f_skip_bin
3-hop, Contrastive, GAT, AMS	$\tilde{D}_s^{-1/2} W_2 \tilde{D}_s^{-1/2}$	$AD^{-1}A^T - \text{diag}$	f_skip_weighted
ThreeHopSkipGNN	$\tilde{D}_3^{-1/2} W_3 \tilde{D}_3^{-1/2}$	$W_2 D^{-1} A$	f_3hop

۳-۴ پروتکل ارزیابی دوگانه (Dual-Bank Evaluation Protocol)

برای سنجش عادلانه و فاقد سوگیری کارایی مدل‌ها، ارزیابی تحت پروتکل دوگانه صورت می‌پذیرد. این پروتکل رفتار مدل را هم در شرایط استاندارد و هم در سخت‌ترین سناریوهای آزمون تنش ارزیابی می‌کند.

۳-۴-۱ بانک آزمون یکنواخت (Uniform Test Bank)

در این بانک، مجموعه آزمون رسمی (`test.csv`) بدون تغییر استفاده می‌شود. هدف: ایجاد شرایط کاملاً یکسان با آزمون‌های مقاله مرجع [۷] به منظور مقایسه مستقیم.

۳-۴-۲ بانک آزمون سخت آگاه از نوع موجودیت (Hard Test Bank)

هدف: حذف امکان بهره‌برداری مدل از محبوبیت درجه گره‌ها و اجبار شبکه به یادگیری ساختار واقعی پیوند. این رویکرد با توصیه‌های لی و همکاران [۱۱] درباره محدودیت‌های منفی‌های تصادفی هم‌راستا است.

الگوریتم (تابع `generate_bipartite_aware_hard_negatives` در `src/data/samplers.py`):

گام ۱ - محاسبه درجات: درجات گره‌های تارگت در گراف آموزش محاسبه می‌شود:

$$d_v = \sum_u (A_{\text{train}})_{uv} \quad (3-11)$$

گام ۲ - افراز چارک‌های درجه‌ای: گره‌های تارگت بر اساس صدک‌های ۲۵، ۵۰ و ۷۵ درجات به ۴ باکت تقسیم می‌شوند:

$$\mathcal{B}_0 = \{v : d_v \leq q_{25}\}, \quad \mathcal{B}_1 = \{v : q_{25} < d_v \leq q_{50}\} \quad (3-12)$$

$$\mathcal{B}_2 = \{v : q_{50} < d_v \leq q_{75}\}, \quad \mathcal{B}_3 = \{v : d_v > q_{75}\} \quad (3-13)$$

گام ۳ - نمونه‌برداری هم‌چارک: به ازای هر یال مثبت آزمون (u, v) :

-- چارک درجه‌ای تارگت واقعی v تعیین می‌شود: $b = \text{Bucket}(v)$

-- کاندید منفی v^- از همان چارک انتخاب می‌شود: $v^- \in \mathcal{B}_b$

-- شروط اعتبار بررسی می‌شوند:

-- در گراف دوقطبی: $(u, v^-) \notin \mathcal{E}_{\text{known}}$ و $u \neq v^-$ و v^- از نوع تارگت باشد.

-- در گراف همگن: $(u, v^-) \notin \mathcal{E}_{\text{known}}$ و $(v^-, u) \notin \mathcal{E}_{\text{known}}$ و $u \neq v^-$

گام ۴ - مکانیزم فال‌بک: در صورت عدم یافتن کاندید معتبر پس از ۱۰۰ تلاش در همان چارک، فال‌بک با سقف ۱,۰۰۰ تلاش در فضای کل تارگت‌ها اعمال می‌شود. این مکانیزم برای جلوگیری از حلقه‌های بی‌پایان در نودهایی با درجه اشباع طراحی شده است. صحت رفتار این الگوریتم در آزمون واحد `test_hard_negatives_respect_bipartite_types` اعتبارسنجی شده است.

۳-۴-۳ اصول حاکم بر پروتکل سخت

پایستگی برش دوقطبی (**Bipartite Cut Invariance**): در گراف‌های DTI و GDI، دارو هرگز با داروی دیگر جفت نمی‌شود. نوع موجودیت‌ها حفظ می‌گردد.

بررسی تقارن در گراف‌های همگن: در DDI و PPI، چون گراف بدون جهت است، باید اطمینان حاصل شود که نه (u, v^-) و نه (v^-, u) در مجموعه تعاملات واقعی قرار ندارند. عدم نشت آستانه: آستانه تصمیم‌گیری τ^* صرفاً روی داده‌های اعتبارسنجی محاسبه و سپس منجمد می‌شود (بخش ۵-۱-۳).

۳-۵ معیارهای ارزیابی و انتخاب آستانه

ارزیابی نهایی توسط تابع `evaluate_dual_bank` (ماژول `src/eval/metrics.py`) انجام می‌شود:
انتخاب آستانه بهینه:

$$\tau^* = \arg \max_{\tau \in [0.05, 0.95]} F1(y_{val}, \mathbb{I}(p_{val} \geq \tau)) \quad (3-14)$$

پویش ۹۱ نقطه‌ای در بازه $[0.05, 0.95]$ صرفاً روی احتمالات مجموعه اعتبارسنجی انجام می‌شود. سپس τ^* برای هر دو بانک آزمون منجمد می‌گردد. صحت این جداسازی در آزمون واحد `test_threshold_is_validation_only` تضمین شده است.
معیارهای گزارش‌شده:

- **AUROC**: مساحت زیر منحنی مشخصه عملکرد گیرنده.
- **AUPRC**: مساحت زیر منحنی دقت-بازخوانی - معیار اصلی رتبه‌بندی در این گراف‌های نامتوازن.
- **F1**: شاخص تعادلی دقت و بازخوانی در آستانه τ^* .
- **Brier Score**: میانگین خطای مربعی احتمالات.

فصل ۴

فرمولاسیون ریاضی و معماری روش‌های پیشنهادی

۴-۱ چارچوب مفهومی یکپارچه

تمامی مدل‌های این پژوهش بر پایه یک چارچوب محاسباتی انتها-به-انتها طراحی شده‌اند که شامل سه رکن اصلی است:

رکن اول - انکودر ساختاری: دریافت ویژگی‌های گره X و ماتریس‌های فیلتر توپولوژیک تنک (F), F_s , F_3 و استخراج ماتریس امبدینگ نهفته $E \in \mathbb{R}^{N \times d_2}$.

رکن دوم - استخراج روابط جفتی: نگاشت غیرخطی امبدینگ گره‌های مبدا و مقصد به فضای تعاملی.

رکن سوم - دیکودر و طبقه‌بندی پیوند: برآورد لاجیت خام $\text{Logit}(u, v) \in \mathbb{R}$ جهت ارزیابی در تابع زیان کراس‌انتروپی باینری.

چهار مدل پیشنهادی این پژوهش هر یک بر بُعد مشخصی از محدودیت‌های شناسایی شده در فصل دوم تمرکز دارند:

جدول ۴-۱: خلاصه چهار مدل پیشنهادی و محدودیت هدف‌گذاری شده

مدل	کلید در کد	نوع پرش	محدودیت هدف	مکانیزم کلیدی
AMS-SkipGNN	ams	پیوسته (وزن دار)	پرش باینری + دیکودر خطی + ادغام ثابت	گیتینگ سیگموئیدی + دیکودر ۴ گانه
SkipGATv2	gat	پیوسته (وزن دار)	انتشار ثابت لاپلاسی	توجه پویا لبه‌ای + ادغام گیتینگ
ThreeHopSkipGNN	3hop	پیوسته + ۳-گام	بن‌بست دوقطبی	سه کانال موازی + گیت سافت‌مکس
ContrastiveSkipGNN	contrastive	پیوسته (وزن دار)	پایداری فضای بازنمایی	دو برج مستقل + InfoNCE متقارن

۴-۲ مدل پیشنهادی ۱: AMS-SkipGNN

مدل AMS-SkipGNN (Attentive Multi-Scale SkipGNN) سه محدودیت اول شناسایی شده در فصل دوم را به‌طور همزمان هدف قرار می‌دهد. این مدل در کلاس AMSSkipGNN (فایل `src/models/ams_skipgnn.py`) پیاده‌سازی شده و `skip_kind = "weighted"` اعلام می‌کند.

۴-۲-۱ معادلات انتشار پیام در لایه اول انکودر

در لایه اول، پیام‌ها به‌صورت موازی در دو نمای مستقیم و پرش وزن دار منتشر می‌شوند:

کانال مستقیم اصلی:

$$H_{\text{orig}}^{(1)} = FXW_o^{(0)} \in \mathbb{R}^{N \times d_1} \quad (4-1)$$

کانال متقاطع پرش-به-اصلی:

$$H_{\text{skip-cross}}^{(1)} = F_s X W_{so}^{(0)} \in \mathbb{R}^{N \times d_1} \quad (4-2)$$

که در آن $W_o^{(0)}, W_{so}^{(0)} \in \mathbb{R}^{d_{\text{in}} \times d_1}$ ماتریس‌های تبدیل خطی هستند و $d_1 = 64$.

۴-۲-۲ واحد گیتینگ تطبیقی باقی‌مانده

به‌جای جمع بدون وزن ($H_{\text{orig}} + H_{\text{skip-cross}}$) که در SkipGNN استفاده می‌شد، مدل یک بردار گیت وابسته به داده برای تک‌تک گره‌ها یاد می‌گیرد. در کد، این عمل در تابع `_fuse` پیاده‌سازی شده است:

$$g_1 = \sigma \left([H_{\text{orig}}^{(1)} \parallel H_{\text{skip-cross}}^{(1)}] w_{g1} + b_{g1} \right) \in \mathbb{R}^{N \times 1} \quad (4-3)$$

که در آن $w_{g1} \in \mathbb{R}^{2d_1}$ بردار وزن گیت و $\sigma(\cdot)$ تابع سیگموئید است. خروجی نمای مستقیم با ترکیب محدب زیر محاسبه می‌شود:

$$O^{(1)} = \text{ReLU} \left(g_1 \odot H_{\text{orig}}^{(1)} + (1 - g_1) \odot H_{\text{skip-cross}}^{(1)} \right) \quad (4-4)$$

سپس نمای پرش لایه اول با دریافت پیام متقاطع از $O^{(1)}$ به‌روزرسانی می‌گردد:

$$S^{(1)} = \text{ReLU} \left(F_s X W_s^{(0)} + F O^{(1)} W_{os}^{(0)} \right) \quad (4-5)$$

۴-۲-۳ معادلات انتشار پیام در لایه دوم انکودر

امبدینگ‌های میانی لایه اول پس از اعمال خاموشی تصادفی (Dropout با احتمال $p = 0.5$) وارد لایه دوم می‌شوند:

$$H_{\text{orig}}^{(2)} = F\hat{O}^{(1)}W_o^{(1)} \in \mathbb{R}^{N \times d_2} \quad (۴-۶)$$

$$H_{\text{skip}}^{(2)} = F_s\hat{S}^{(1)}W_{s2o}^{(1)} \in \mathbb{R}^{N \times d_2} \quad (۴-۷)$$

ترکیب نهایی امبدینگ‌های لایه دوم توسط گیت تطبیقی دوم صورت می‌پذیرد:

$$g_2 = \sigma \left([H_{\text{orig}}^{(2)} \parallel H_{\text{skip}}^{(2)}]w_{g2} + b_{g2} \right) \quad (۴-۸)$$

$$E = g_2 \odot H_{\text{orig}}^{(2)} + (1 - g_2) \odot H_{\text{skip}}^{(2)} \in \mathbb{R}^{N \times d_2} \quad (۴-۹)$$

۴-۲-۴ دیکودر تانسوری تعاملی ۴گانه

برای هر جفت کاندید (u, v) بردارهای امبدینگ $E_u, E_v \in \mathbb{R}^{d_2}$ استخراج شده و تانسور تعاملی زیر با ابعاد $4d_2$ تشکیل می‌شود:

$$Z_{uv} = [E_u \parallel E_v \parallel (E_u \odot E_v) \parallel |E_u - E_v|] \in \mathbb{R}^{4d_2} \quad (۴-۱۰)$$

لاجیت نهایی از طریق یک لایه غیرخطی با نرمال‌سازی دسته‌ای به دست می‌آید:

$$H_{\text{dec}} = \text{Dropout} \left(\text{ReLU} \left(\text{BatchNorm1d}(Z_{uv}W_{d1} + b_{d1}) \right), p \right) \quad (۴-۱۱)$$

$$\text{Logit}(u, v) = H_{\text{dec}} W_{d2} + b_{d2} \in \mathbb{R} \quad (4-12)$$

که در آن $W_{d1} \in \mathbb{R}^{4d_2 \times d_{\text{dec}}}$ ($d_{\text{dec}} = 64$) و $W_{d2} \in \mathbb{R}^{d_{\text{dec}} \times 1}$ است. استفاده از BatchNorm1d مقیاس چهار مولفه ناهمگن تانسور تعاملی را پیش از ورود به پرسپترون متعادل می‌سازد.

۴-۳ مدل پیشنهادی ۲: SkipGATv2

مدل SkipGATv2 محدودیت انتشار ثابت لاپلاسی را هدف قرار می‌دهد. با جایگزینی کانولوشن ثابت با مکانیزم توجه پویا لبه‌ای، شبکه قادر است یال‌های کم‌اطلاع را به‌صورت خودکار کم‌اهمیت کند [۲]. این مدل در کلاس SkipGATv2 (فایل src/models/skip_gat.py) پیاده‌سازی شده است.

۴-۳-۱ لایه توجه تنک SparseGATv2Layer

برای یک لایه با K سر توجه ($K = 4$) و بعد هر سر $d_k = 16$ ، به‌طوری‌که $d_{\text{out}} = K \cdot d_k = 64$:
نگاشت خطی ویژگی‌های مبدا و مقصد:

$$h^{\text{src}} = XW_{\text{src}}, \quad h^{\text{dst}} = XW_{\text{dst}} \in \mathbb{R}^{N \times (K \cdot d_k)} \quad (4-13)$$

امتیازدهی پویا به ازای یال‌های موجود $(i, j) \in \mathcal{E}$ در سر k :

$$e_{ij}^k = (\mathbf{a}_k)^T \text{LeakyReLU}(h_{i,k}^{\text{src}} + h_{j,k}^{\text{dst}}, \alpha = 0.2) \quad (4-14)$$

که در آن $\mathbf{a}_k \in \mathbb{R}^{d_k}$ بردار توجه یادگیرنده است. توجه داشته باشید که برخلاف GAT نسخه اول، در GATv2 غیرخطی‌سازی پیش از ضرب با بردار توجه اعمال می‌شود. این ترتیب، مشکل توجه ایستا را برطرف می‌سازد [۲].

سافت مکس تنک پایدار عددی:

$$\text{score}_{ij}^k = e_{ij}^k - \max_{m \in \mathcal{N}(i)} e_{im}^k \quad (4-2?)$$

$$\alpha_{ij}^k = \frac{\exp(\text{score}_{ij}^k)}{\sum_{m \in \mathcal{N}(i)} \exp(\text{score}_{im}^k) + 10^{-12}} \quad (4-2?)$$

تجميع پیام‌ها:

$$h_i^{(l+1)} = \left\| \sum_{k=1}^K \left(\sum_{j \in \mathcal{N}(i)} \alpha_{ij}^k \cdot h_{j,k}^{\text{dst}} \right) + \text{bias} \right\| \quad (4-2?)$$

۴-۳-۲ معماری انکودر متقابل دوکاناله

در این مدل، تمام عملگرهای انتشار با لایه‌های SparseGATv2Layer جایگزین شده‌اند و تابع فعال‌ساز ELU به جای ReLU استفاده می‌شود:

لایه اول:

$$H_{\text{orig}}^{(1)} = \text{GATv2}_o(X, F), \quad H_{\text{skip-cross}}^{(1)} = \text{GATv2}_{so}(X, F_s) \quad (4-2?)$$

$$O^{(1)} = \text{ELU} \left(g_1 \odot H_{\text{orig}}^{(1)} + (1 - g_1) \odot H_{\text{skip-cross}}^{(1)} \right) \quad (4-2?)$$

$$S^{(1)} = \text{ELU} \left(\text{GATv2}_s(X, F_s) + \text{GATv2}_{os}(O^{(1)}, F) \right) \quad (4-20)$$

لایه دوم:

$$E = g_2 \odot \text{GATv2}_{o2}(O^{(1)}, F) + (1 - g_2) \odot \text{GATv2}_{s2o}(S^{(1)}, F_s) \quad (4-21)$$

۳-۳-۴ الگوریتم توجه تکه‌ای برای گراف‌های کلان

در گراف‌های بسیار بزرگ (مانند GDI با ۱۹,۷۸۳ نود)، ساخت همزمان تانسورهای میانی $(|\mathcal{E}|, K, d_k)$ ممکن است از حافظه GPU فراتر رود. راهکار پیاده‌سازی شده، عملگر مشتق‌پذیر سفارشی `torch.autograd.Function` `_ChunkedSparseGATv2` ذیل است.

شرط انتخاب مسیر:

$$\text{path} = \begin{cases} \text{vectorized} & \text{if } |\mathcal{E}| \cdot K \cdot d_k \cdot s \leq 384\text{MB} \\ \text{chunked} & \text{otherwise} \end{cases} \quad (4-22)$$

که در آن s اندازه هر عنصر (۴ بایت برای `float32`) است. در مسیر تکه‌ای، یال‌ها در تکه‌های 1,048,576 تایی پردازش می‌شوند و قله مصرف حافظه از $O(|\mathcal{E}|)$ به $O(\text{chunk})$ کاهش می‌یابد. صحت این پیاده‌سازی در آزمون واحد `test_chunked_gat_matches_large_chunk` اعتبارسنجی شده است.

۴-۴ مدل پیشنهادی ۳: ThreeHopSkipGNN

مدل `ThreeHopSkipGNN` به‌طور اختصاصی بن‌بست هندسی گراف‌های دوقطبی (محدودیت اول در فصل دوم) را هدف قرار می‌دهد. این مدل در کلاس `ThreeHopSkipGNN` (فایل `src/models/three_hop_skipgnn.py`) پیاده‌سازی شده و `skip_kind = "three_hop_bundle"` اعلام می‌کند.

۴-۴-۱ انکودر سه‌شاخه چندمقیاسی

این مدل در هر لایه دارای سه عملگر کانوولوشن گراف موازی است که به‌طور همزمان روی فیلترهای لاپلاسی F_1 (گراف اصلی)، F_2 (پرش ۲-گام) و F_3 (مسیر بازگشت ۳-گام) عمل می‌کنند: انتشار لایه اول:

$$H_1^{(1)} = \text{ReLU} \left(F_1 X W_1^{(0)} \right) \in \mathbb{R}^{N \times d_1} \quad (4-23)$$

$$H_2^{(1)} = \text{ReLU} \left(F_2 X W_2^{(0)} \right) \in \mathbb{R}^{N \times d_1} \quad (4-24)$$

$$H_3^{(1)} = \text{ReLU} \left(F_3 X W_3^{(0)} \right) \in \mathbb{R}^{N \times d_1} \quad (4-25)$$

۲-۴-۴ گیتینگ برداری سه کاناله با سافت مکس

برای ترکیب امبدینگ‌های سه گانه، یک مکانیزم توجه مسیر یادگیرنده طراحی شده است. برای هر شاخه $m \in \{1, 2, 3\}$ ، یک بردار توجه $\mathbf{v}_m \in \mathbb{R}^{d_1}$ تعریف می‌شود:

محاسبه امتیاز هر مسیر:

$$s_m(i) = H_{m,i}^{(1)} \cdot \mathbf{v}_m^{(1)} \in \mathbb{R} \quad (4-26)$$

نرمال سازی وزن ها با سافت مکس:

$$\gamma_m(i) = \frac{\exp(s_m(i))}{\sum_{k=1}^3 \exp(s_k(i))}, \quad \sum_{m=1}^3 \gamma_m(i) = 1 \quad (4-27)$$

تجميع محدب:

$$H_{\text{fused},i}^{(1)} = \gamma_1(i) H_{1,i}^{(1)} + \gamma_2(i) H_{2,i}^{(1)} + \gamma_3(i) H_{3,i}^{(1)} \quad (4-28)$$

انتشار لایه دوم:

$$E_i = \sum_{m=1}^3 \gamma_m^{(2)}(i) \cdot F_m H_{\text{fused}}^{(1)} W_m^{(1)} \quad (4-29)$$

امبدینگ نهایی E وارد دیکودر تانسوری تعاملی ۴گانه (معادلات ۴-۱۰ تا ۴-۱۲) می‌شود.

۴-۵ مدل پیشنهادی ۴: ContrastiveSkipGNN

مدل ContrastiveSkipGNN محدودیت پایداری فضای بازنمایی را هدف قرار می‌دهد. این مدل در کلاس ContrastiveSkipGNN (فایل src/models/contrastive_skipgnn.py) پیاده‌سازی شده و skip_kind = "weighted" اعلام می‌کند.

۴-۵-۱ انکودر دو نمایی مستقل

شبکه به‌طور همزمان دو نمای ساختاری از گراف را پردازش می‌کند:
نمای مستقیم:

$$H^{(1)} = \text{Dropout}(\text{ReLU}(\text{GCN}_{o1}(X, F)), p), \quad H^{(2)} = \text{GCN}_{o2}(H^{(1)}, F) \quad (4-30)$$

نمای پرش:

$$S^{(1)} = \text{Dropout}(\text{ReLU}(\text{GCN}_{s1}(X, F_s)), p), \quad S^{(2)} = \text{GCN}_{s2}(S^{(1)}, F_s) \quad (4-31)$$

ادغام دو نما:

$$g = \sigma \left([H^{(2)} \parallel S^{(2)}] w_{\text{fuse}} + b_{\text{fuse}} \right) \quad (4-32)$$

$$E = g \odot H^{(2)} + (1 - g) \odot S^{(2)} \quad (4-33)$$

۴-۵-۲ سرهای تصویر غیرخطی

امبدینگ‌های لایه دوم دو نما وارد دو پرسپترون دولایه مجزا شده و روی کره واحد نرمال‌سازی می‌شوند:

$$z_i = \frac{\text{MLP}_o(H_i^{(2)})}{\|\text{MLP}_o(H_i^{(2)})\|_2}, \quad \tilde{z}_i = \frac{\text{MLP}_s(S_i^{(2)})}{\|\text{MLP}_s(S_i^{(2)})\|_2} \in \mathbb{R}^{d_{\text{proj}}} \quad (4-34)$$

که در آن $d_{\text{proj}} = 32$ و $\text{MLP}(h) = W_2 \cdot \text{ReLU}(W_1 h + b_1) + b_2$.

۳-۵-۴ تابع زیان تقارنی InfoNCE

در هر بیج آموزشی، برای مجموعه گره‌های فعال، زوج $(z_i, \tilde{z}_i)$ به عنوان نمونه مثبت و جفت‌های $(z_i, \tilde{z}_j)$ به ازای $j \neq i$ به عنوان نمونه منفی تعریف می‌شوند:

$$\mathcal{L}_{o \rightarrow s} = -\frac{1}{|\mathcal{B}|} \sum_{i \in \mathcal{B}} \log \frac{\exp(z_i^T \tilde{z}_i / \tau)}{\sum_{j \in \mathcal{B}} \exp(z_i^T \tilde{z}_j / \tau)} \quad (4-4?)$$

$$\mathcal{L}_{s \rightarrow o} = -\frac{1}{|\mathcal{B}|} \sum_{i \in \mathcal{B}} \log \frac{\exp(\tilde{z}_i^T z_i / \tau)}{\sum_{j \in \mathcal{B}} \exp(\tilde{z}_i^T z_j / \tau)} \quad (4-4?)$$

$$\mathcal{L}_{\text{CL}} = \frac{1}{2} (\mathcal{L}_{o \rightarrow s} + \mathcal{L}_{s \rightarrow o}) \quad (4-4?)$$

تابع زیان نهایی:

$$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{BCE}} + \lambda \cdot \mathcal{L}_{\text{CL}} \quad (4-4?)$$

که در آن پارامترهای تنظیمی $\tau = 0.2$ و $\lambda = 0.1$ هستند. در پیاده‌سازی، زیان مقابله‌ای تنها در حالت آموزش (`model.training == True`) محاسبه و به تابع زیان اصلی افزوده می‌شود. در حالت ارزیابی، خروجی مدل صرفاً دو مقدار `(logits, embeddings)` است.

۴-۶ مدل‌های خط مبنا

برای سنجش میزان بهبود ناشی از هر یک از نوآوری‌ها، سه خط مبنا در پایین‌ترین بازپیاپی‌سازی شدند:

جدول ۴-۲: مشخصات فنی خطوط مبنای پیاده‌سازی شده

skip_kind	دیکودر	ادغام	ماتریس‌های پیام‌رسانی	کلاس در کد	مدل
"none"	$[E_u \parallel E_v]$ الحاق خطی	-	فقط F	StandardGCN	GCN
"binary"	$[E_u \parallel E_v]$ الحاق خطی	جمع ساده	F_s^{bin} و F	SkipGNNBaseline	SkipGNN
-	ضرب ماتریسی ۳-گام (دوقطبی)	غیرپارامتری	A_{train}	-	(RA) Heuristic

نکته درباره هوریستیک: در گراف‌های همگن، امتیاز بر پایه همسایگان مشترک وزن‌دار محاسبه می‌شود. در گراف‌های دوقطبی، از آنجا که همسایگان مشترک ۱-گام تهی هستند، از ضرب ماتریسی ۳-گام استفاده می‌شود (تابع `_bipartite_three_walk_scores` در `src/models/heuristics.py`).

۴-۷ نردبان ابلیشن مدولار

به‌منظور تفکیک سهم مستقل هر یک از اجزای معماری در افزایش کارایی، یک نردبان ابلیشن ۴ مرحله‌ای طراحی شده است. این نردبان در تابع `make_ablation` (فایل `src/models/ams_skipgnn.py`) و اسکریپت `scripts/run_ablation.py` پیاده‌سازی شده است:

جدول ۴-۳: ساختار گام‌های چهارگانه مطالعه ابلیشن

گام	شناسه	نوع پرش	ادغام	دیکودر
۰	0_skipgnn	باینری $\text{sign}(AA^T)$	جمع ساده	الحاق خطی
۱	1_weighted	پیوسته تخصیص منابع	جمع ساده	الحاق خطی
۲	2_gated	پیوسته تخصیص منابع	گیتینگ سیگموئیدی	الحاق خطی
۳	3_full	پیوسته تخصیص منابع	گیتینگ سیگموئیدی	تانسوری ۴ گانه + BatchNorm

این نردبان ابلیشن به‌طور شفاف مشخص می‌کند که آیا بهبود دقت ناشی از اصلاح فیلتر پرش بوده، یا گیتینگ تطبیقی، یا استخراج تعاملات غیرخطی در دیکودر تانسوری. نتایج عددی این ابلیشن در فصل پنجم گزارش می‌شود.

فصل ۵

پروتکل آموزش، آزمایش‌های تجربی و تحلیل جامع نتایج

۵-۱ پروتکل آموزش و تنظیمات آزمایشگاهی

۵-۱-۱ زیرساخت محاسباتی و استراتژی آموزش

تمامی آزمایش‌های گزارش شده در این فصل بر روی پردازنده گرافیکی NVIDIA Tesla T4 (با ۱۶ گیگابایت حافظه VRAM) در بستر ابری Kaggle اجرا شده‌اند. پایپ‌لاین آموزش بر پایه یک استراتژی دو مرحله‌ای طراحی شده است:

مرحله انکودینگ (Full-Graph Forward): کل ماتریس ویژگی X و ماتریس‌های تنک مجاورت (F_3, F_s, F) در هر فراخوانی در حافظه GPU پردازش شده و امبدینگ تمام N گره تولید می‌شود.

مرحله دیکودینگ دسته‌ای (Decoder-Only Batching): دسته‌بندی صرفاً روی جفت‌یال‌های دیکودر اعمال می‌شود.

نکته روش‌شناختی مهم: در پروتکل گزارش شده، انکودر در هر بچ دیکودر مجدداً فراخوانی می‌شود (Encode Every Batch). این بدان معناست که به ازای هر بچ آموزشی، یک گام کامل بهینه‌سازی Adam انجام می‌شود. این پروتکل با مدل مرجع SkipGNN هم‌خوان است و از کم‌برازش جلوگیری می‌کند. پرچم `--encode-once` (که انکودر را فقط یک بار در هر اپاک فراخوانی می‌کند) صرفاً یک بهینه‌سازی سرعت است و برای نتایج گزارش شده استفاده نشده است.

۵-۱-۲ هاپرپارامترهای مشترک

جدول ۵-۱ تنظیمات مشترک تمامی مدل‌های عصبی را نشان می‌دهد:

۵-۱-۳ تنظیمات اختصاصی هر دیتاست و پروتکل مقایسه

جدول ۵-۲ تنظیمات اختصاصی دیتاست‌ها و وضعیت پروتکل مقایسه را نشان می‌دهد. ستون آخر مشخص می‌کند که مقایسه هر مدل با مدل مرجع در آن دیتاست معتبر است یا با محدودیت مواجه است:

توضیح: در دیتاست‌های DDI، PPI و GDI، مدل‌های اضافی (Contrastive, 3-hop, SkipGATv2) با بچ‌سایز ۱۰۲۴ اجرا شده‌اند که تعداد گام‌های Adam کمتری نسبت به مدل‌های مبنا (بچ ۱۲۸ یا ۲۵۶) دریافت کرده‌اند. این تفاوت در تعداد گام‌های بهینه‌سازی به‌عنوان یک محدودیت مقایسه‌ای در تفسیر

جدول ۵-۱: هایپرپارامترهای مشترک آموزش

پارامتر	مقدار	منبع در کد
بعد فضای نهفته ($d_1 = d_2$)	۶۴	hidden_dim :configs/default.yaml
بعد دیکودر (d_{dec})	۶۴	:configs/default.yaml decoder_hidden
احتمال خاموشی تصادفی (Dropout)	۰.۵	dropout :configs/default.yaml
نرخ یادگیری (Adam)	10^{-3}	lr :configs/default.yaml
جریمه وزن (Weight Decay)	5×10^{-4}	weight_decay :configs/default.yaml
حد برش گرادینان (Gradient Clip)	۰.۵	grad_clip :configs/default.yaml
ویژگی‌های ورودی	وان-هات تنک (I_N)	input_type :configs/default.yaml
سیدهای تصادفی	۷, ۱۲۳, ۴۲	seeds_stage1 :configs/default.yaml
تابع زیان	BCEWithLogitsLoss	src/training/trainer.py
زیان مقابله‌ای (Contrastive)	فقط $\tau = 0.2, \lambda_{CL} = 0.1$	src/models/contrastive_skipgmn.py

جدول ۵-۲: تنظیمات اختصاصی دیتاست‌ها و اعتبار مقایسه

دیتاست	اپاک	صبر	بج (مینا)	بج (مدل‌های اضافی)	گام‌های Adam/اپاک (مینا)	گام‌های Adam/اپاک (اضافی)	وضعیت مقایسه
DTI	۳۰	۸	۱۲۸	۱۲۸	۱۶۵	۱۶۵	هم‌خوان کامل
DDI	۳۰	۸	۱۲۸	۱۰۲۴	۵۳۰	۶۶	اضافی‌ها گام کمتر
PPI	۳۰	۸	۱۲۸	۱۰۲۴	۲۵۵	۳۱	اضافی‌ها گام کمتر
GDI	۲۰	۶	۲۵۶	۱۰۲۴	۴۴۷	۱۱۱	اضافی‌ها گام کمتر

نتایج این دیتاست‌ها لحاظ شده است. با این حال، برتری مدل‌های اضافی در این دیتاست‌ها با وجود گام‌های کمتر، به‌عنوان شواهدی بر کارآمدی معماری آن‌ها (نه صرفاً بودجه محاسباتی بیشتر) تفسیر می‌شود. این نکته در فصل ششم به تفصیل بحث شده است.

در دیتاست DTI، تمام مدل‌ها با بج‌سایز یکسان ۱۲۸ اجرا شده‌اند و مقایسه کاملاً هم‌خوان است.

۵-۱-۴ مکانیزم توقف زودهنگام و انتخاب آستانه

توقف زودهنگام: در انتهای هر اپاک، مساحت زیر منحنی دقت-بازخوانی اعتبارسنجی (Val AUPRC) محاسبه می‌شود. بهترین حالت مدل ذخیره شده و در صورت عدم بهبود به مدت patience اپاک متوالی، آموزش خاتمه می‌یابد.

انتخاب آستانه تصمیم‌گیری (τ^*): آستانه بهینه‌ساز شاخص F1 با پویش ۹۱ نقطه‌ای در بازه $[0.05, 0.95]$ صرفاً روی احتمالات مجموعه اعتبارسنجی استخراج و سپس برای ارزیابی نهایی منجمد می‌گردد:

$$\tau^* = \arg \max_{\tau \in [0.05, 0.95]} F1(y_{val}, \mathbb{I}(p_{val} \geq \tau)) \quad (5-1)$$

صحت این جداسازی در آزمون واحد `test_threshold_is_validation_only` تضمین شده است.

۵-۱-۵ ملاحظات آماری و معیار پراکندگی

تعداد سیدها: تمامی آزمایش‌ها با ۳ سید تصادفی (۴۲، ۱۲۳، ۷) اجرا شده‌اند. این تعداد به دلیل محدودیت‌های محاسباتی پروتکل ارزیابی دوگانه (ساخت بانک منفی سخت، آموزش ۷ مدل، و ۴ دیتاست بر روی GPU T4) انتخاب شده است.

معیار پراکندگی: انحراف معیار (SD) در میان ۳ سید گزارش می‌شود. در تحلیل‌های تطبیقی، عدم هم‌پوشانی بازه‌های میانگین $\pm$ انحراف معیار به‌عنوان شاخص اولیه تمایز عملکرد در نظر گرفته شده است.

معیار تمایز آماری: در این گزارش، دو مدل از نظر آماری «قابل تفکیک» تلقی می‌شوند که بازه‌های $[Mean - SD, Mean + SD]$ آن‌ها با یکدیگر هم‌پوشانی نداشته باشند. در صورت هم‌پوشانی بازه‌ها، دو مدل «هم‌سطح آماری» تلقی شده و ادعای برتری یکی بر دیگری معتبر نیست.

محدودیت: آزمون‌های معناداری آماری رسمی (مانند paired t-test یا Wilcoxon signed-rank) به دلیل تعداد محدود سیدها انجام نشده‌اند. این محدودیت در فصل ششم به‌صراحت ذکر شده است.

۵-۲ نتایج تجربی کلان: ارزیابی هفت مدل

۵-۲-۱ ماتریس جامع نتایج AUPRC

جدول ۵-۳ نتایج مساحت زیر منحنی دقت-بازخوانی (AUPRC) را در هر دو بانک آزمون یکنواخت و سخت گزارش می‌کند. مقادیر به فرم $Mean \pm SD$ در میان ۳ سید هستند. علامت * برترین عملکرد در هر ستون را نشان می‌دهد.

جدول ۵-۳: نتایج AUPRC در بانک‌های یکنواخت و سخت (میانگین $\pm$ انحراف معیار، ۳ سید)

مدل	DTI Uniform	DTI Hard	DDI Uniform	DDI Hard	PPI Uniform	PPI Hard	GDI Uniform	GDI Hard
GCN	0.916 $\pm$ 0.000	0.731 $\pm$ 0.002	0.907 $\pm$ 0.000	0.658 $\pm$ 0.001	0.920 $\pm$ 0.001	0.609 $\pm$ 0.015	0.934 $\pm$ 0.001	0.749 $\pm$ 0.008
SkipGNN	0.929 $\pm$ 0.001	0.695 $\pm$ 0.012	0.929 $\pm$ 0.001	0.724 $\pm$ 0.005	0.928 $\pm$ 0.002	0.622 $\pm$ 0.012	0.934 $\pm$ 0.002	0.720 $\pm$ 0.012
(RA) Heuristic	0.806	0.776	0.890	0.672	0.671	0.578	0.917	* 0.842 $\pm$ 0.001
SkipGATv2	0.912 $\pm$ 0.008	* 0.804 $\pm$ 0.005	0.967 $\pm$ 0.004	0.900 $\pm$ 0.007	0.895 $\pm$ 0.005	* 0.778 $\pm$ 0.006	0.934 $\pm$ 0.007	0.837 $\pm$ 0.003
3-hop	0.920 $\pm$ 0.004	0.803 $\pm$ 0.015	0.978 $\pm$ 0.002	0.895 $\pm$ 0.009	0.933 $\pm$ 0.003	0.688 $\pm$ 0.021	0.950 $\pm$ 0.004	0.832 $\pm$ 0.003
Contrastive	0.918 $\pm$ 0.002	0.800 $\pm$ 0.017	0.980 $\pm$ 0.001	0.905 $\pm$ 0.003	0.933 $\pm$ 0.003	0.657 $\pm$ 0.025	0.949 $\pm$ 0.003	0.833 $\pm$ 0.008
AMS-SkipGNN	0.920 $\pm$ 0.006	0.798 $\pm$ 0.011	0.980 $\pm$ 0.001	* 0.912 $\pm$ 0.003	0.931 $\pm$ 0.004	0.674 $\pm$ 0.016	0.951 $\pm$ 0.001	0.829 $\pm$ 0.003

تحلیل اولیه:

-- در بانک یکنواخت، تمام مدل‌های عصبی در محدوده 0.89 تا 0.98 قرار دارند و تمایز معناداری میان آن‌ها مشاهده نمی‌شود.

-- در بانک سخت، تفاوت‌های عملکردی آشکار می‌شوند: مدل مرجع SkipGNN در تمام چهار دیتاست افت قابل توجهی نشان می‌دهد.

-- در دیتاست GDI، هوریستیک تحلیلی تخصیص منابع با 0.842 بالاترین امتیاز را کسب کرده است.

۵-۲-۲ تحلیل هم‌سطحی آماری در دیتاست DTI

در دیتاست DTI، سه مدل پیشنهادی - AMS (0.798 ± 0.011)، SkipGATv2 (0.804 ± 0.005) و 3-hop (0.803 ± 0.015) - بازه‌های انحراف معیار هم‌پوشانی دارند:

-- بازه AMS: $[0.787, 0.809]$

-- بازه SkipGATv2: $[0.799, 0.809]$

-- بازه 3-hop: $[0.788, 0.818]$

طبق معیار عدم هم‌پوشانی بازه‌ها (بخش ۵-۱-۵)، این سه مدل از نظر آماری قابل تفکیک نیستند و هم‌سطح تلقی می‌شوند. برتری عددی SkipGATv2 ($+0.006$ نسبت به AMS) در محدوده نويز سیدی است.

۵-۲-۳ ماتریس نتایج AUROC و F1

جدول ۵-۴: نتایج Hard AUROC و F1 در آستانه بهینه τ^* (میانگین $\pm$ انحراف معیار، ۳ سید)

مدل	DTI Hard AUROC	DTI F1	DDI Hard AUROC	DDI F1	PPI Hard AUROC	PPI F1	GDI Hard AUROC	GDI F1
GCN	0.695 ± 0.003	0.843 ± 0.001	0.704 ± 0.002	0.865 ± 0.001	0.631 ± 0.008	0.842 ± 0.004	0.732 ± 0.012	0.860 ± 0.003
SkipGNN	0.660 ± 0.020	0.858 ± 0.001	0.758 ± 0.007	0.876 ± 0.003	0.638 ± 0.012	0.849 ± 0.003	0.704 ± 0.010	0.859 ± 0.001
SkipGATv2	0.773 ± 0.006	0.816 ± 0.005	0.907 ± 0.007	0.923 ± 0.004	0.770 ± 0.006	0.809 ± 0.006	0.829 ± 0.003	0.850 ± 0.004
3-hop	0.770 ± 0.007	0.822 ± 0.012	0.910 ± 0.009	0.933 ± 0.010	0.706 ± 0.020	0.851 ± 0.004	0.832 ± 0.005	0.889 ± 0.003
Contrastive	0.768 ± 0.002	0.820 ± 0.001	0.918 ± 0.004	0.941 ± 0.002	0.677 ± 0.017	0.861 ± 0.003	0.826 ± 0.008	0.888 ± 0.002
AMS	0.759 ± 0.013	0.818 ± 0.017	0.918 ± 0.003	0.938 ± 0.001	0.695 ± 0.011	0.852 ± 0.008	0.823 ± 0.002	0.887 ± 0.002


۵-۳ تحلیل تفصیلی نمودارها

۵-۳-۱ شکل ۱: مقایسه همزمان آزمون یکنواخت و سخت

این نمودار میله‌ای دوپنلی، عملکرد تمام هفت مدل را در دو شرایط Uniform AUPRC (پنل چپ) و Hard AUPRC (پنل راست) به تصویر می‌کشد. میله‌ها نشان‌دهنده میانگین و خطوط خطا نشان‌دهنده انحراف معیار در میان ۳ سید هستند.

مشاهدات کلیدی:

-- پنل چپ (Uniform): تمام مدل‌های عصبی در محدوده 0.89 تا 0.98 فشرده شده‌اند. مدل



شکل ۵-۱: مقایسه همزمان AUPRC در بانک یکنواخت (چپ) و بانک سخت (راست) برای هفت مدل. میله‌ها میانگین و خطوط خطا انحراف معیار در میان سه سید هستند.

مرجع SkipGNN در DTI با 0.929 در ظاهر رقابتی است.

— پنل راست (Hard): به محض انتقال به منفی‌های هم‌درجه، عملکرد SkipGNN در تمام چهار دیتاست کاهش می‌یابد (به‌ویژه افت از 0.929 به 0.695 در DTI).

— مدل‌های پیشنهادی: در پنل راست، مدل‌های AMS، SkipGATv2، 3-hop و Contrastive در صدر قرار دارند.

تفسیر: این الگو با یافته‌های لی و همکاران [۱۱] درباره محدودیت بنچمارک‌های مبتنی بر منفی‌های تصادفی هم‌راستا است. آزمون یکنواخت به دلیل غلبه منفی‌های کم‌درجه، تمایز ساختاری میان مدل‌ها را پنهان می‌کند.


۵-۳-۲: نردبان ابلیشن

این نمودار سهم مستقل هر یک از اجزای معماری را در جهش عملکردی روی دیتاست DTI نشان می‌دهد. نتایج عددی ابلیشن در جدول ۵-۵ خلاصه شده‌اند:

جدول ۵-۵: نتایج نردبان ابلیشن در دیتاست DTI (Hard AUPRC)

گام	شناسه	تغییر	Hard AUPRC
۰	0_skipgnn	پرش باینری + جمع ساده + دیکودر الحاقی	0.703 ± 0.011
۱	1_weighted	پرش وزن‌دار + جمع ساده + دیکودر الحاقی	0.698 ± 0.009
۲	2_gated	پرش وزن‌دار + گیتینگ + دیکودر الحاقی	0.686 ± 0.013
۳	3_full	پرش وزن‌دار + گیتینگ + دیکودر تانسوری	0.788 ± 0.010

تحلیل:



شکل ۲-۵: نردبان ابلیشن چهارمرحله‌ای مدل AMS روی دیتاست DTI در معیار Hard AUPRC.

-- افزودن پرش وزن دار به تنهایی (گام ۰ ← ۱) بهبود معناداری ایجاد نمی‌کند و حتی افت جزئی مشاهده می‌شود.

-- افزودن گیتینگ بدون اصلاح دیکودر (گام ۱ ← ۲) نیز بهبودی نشان نمی‌دهد.


-- جهش اصلی با افزودن دیکودر تانسوری ۴ گانه (گام ۲ ← ۳) رخ می‌دهد: بهبود مطلق +0.102 واحد درصد.

تفسیر: این یافته نشان می‌دهد که بهبود مدل AMS صرفاً ناشی از یک مؤلفه منفرد نیست، بلکه نتیجه هم‌افزایی میان بازنمایی پیوسته پرش، ادغام تطبیقی، و ظرفیت تعاملی دیکودر تانسوری است. دیکودر الحاقی ساده، حتی با بازنمایی بهبودیافته، قادر به استخراج تعاملات غیرخطی لازم برای تفکیک منفی‌های سخت نیست.

محدودیت: ابلیشن صرفاً روی دیتاست DTI اجرا شده است. تعمیم این یافته به سایر دیتاست‌ها نیازمند اجرای ابلیشن بر روی حداقل یک دیتاست همگن (مانند DDI) است که به‌عنوان کار آینده پیشنهاد می‌شود.

۳-۳-۵ شکل ۳: مقاومت در برابر حذف یال

این نمودار رفتار مدل‌ها را با حذف تصادفی ۱۰٪ تا ۹۰٪ از یال‌های آموزشی در دیتاست DTI نشان می‌دهد.



شکل ۳-۵: مقاومت مدل‌ها در برابر حذف تصادفی یال‌های آموزشی در دیتاست DTI.

مشاهدات:

- در تمام نسبت‌های حذف (0.1 تا 0.9)، مدل AMS بالاتر از SkipGNN و بالاتر از GCN قرار دارد.
- حتی با حذف ۹۰٪ یال‌ها، مدل AMS همچنان AUPRC بالای 0.910 را حفظ می‌کند.
- شیب نزولی عملکرد در مدل‌های پیشنهادی ملایم‌تر از خطوط مبنا است.

تفسیر: پایداری در برابر فقر داده نشان می‌دهد که عملگر تخصیص منابع و دیکودر تانسوری، ساختارهای توپولوژیک را به‌صورت کارآمدتری از گراف تنک استخراج می‌کنند.


۵-۳-۴ شکل ۴: منحنی‌های دقت-بازخوانی

منحنی‌های Precision-Recall در سید ۴۲ و در آزمون یکنواخت، رفتار عملیاتی مدل‌ها را نشان می‌دهند.

مشاهدات:

- در دیتاست‌های متراکم (DDI و GDI)، منحنی‌ها تا سطوح بالای بازخوانی، دقت نزدیک به ۱ را حفظ می‌کنند.
- در دیتاست‌های تنک (DTI و PPI)، منحنی‌ها پس از بازخوانی حدود 0.7 شیب نزولی پیدا می‌کنند.
- در بازخوانی کامل (1.0)، دقت به سطح پایه (0.5) می‌رسد که نشان‌دهنده کالیبراسیون صحیح

Precision-recall on the uniform test split (seed 42)




Curves are drawn for every stored `pr_<model>_seed42.npz`. Older runs saved AMS only; AUPRC for all seven models is in fig1.

شکل ۴-۵: منحنی‌های دقت-بازخوانی در آزمون یکنواخت، سید ۴۲. در نسخه فعلی مخزن، آرایه‌های ذخیره‌شده مربوط به مدل AMS هستند؛ رتبه‌بندی هفت مدل در شکل ۱-۵ آمده است.

منحنی‌ها است.

۵-۳-۵: نقشه حرارتی عملکرد



شکل ۵-۵: نقشه حرارتی میانگین Hard AUPRC (دیتاست × مدل) در سه سید.

این ماتریس رنگی (دیتاست × مدل)، میانگین Hard AUPRC را در ۳ سید نشان می‌دهد.

مشاهدات:

-- رنگ‌های آبی تیره (0.80 تا 0.91) در ستون‌های مدل‌های پیشنهادی (به‌ویژه AMS در DDI و SkipGATv2 در PPI) متمرکز هستند.

-- ستون‌های GCN و SkipGNN با رنگ‌های روشن‌تر (0.60 تا 0.75) نشان‌دهنده عملکرد ضعیف‌تر در شرایط سخت هستند.

-- سلول هوریستیک در سطر GDI با رنگ آبی تیره (0.842) نشان‌دهنده برترین عملکرد در آن دیتاست است.


۵-۳-۶: دلتای بهبود نسبت به AMS

این نمودار تفاوت عملکرد هر مدل را نسبت به AMS به‌عنوان خط تراز صفر ($\Delta = \text{Model} - \text{AMS}$) نشان می‌دهد.

تحلیل به تفکیک دیتاست:

دیتاست DDI (دارو-دارو):

-- SkipGNN: $\Delta = -0.188$ (افت قابل توجه)



شکل ۵-۶: دلتای Hard AUPRC هر مدل نسبت به AMS ($\Delta = \text{Model} - \text{AMS}$).

-- GCN: $\Delta = -0.254$ (افت قابل توجه)

-- SkipGATv2, 3-hop, Contrastive: $\Delta \approx -0.007$ تا -0.017 (در محدوده AMS)

دیتاست DTI (دارو-هدف):

-- SkipGNN: $\Delta = -0.103$

-- GCN: $\Delta = -0.067$

-- SkipGATv2: $\Delta = +0.006$ (در محدوده نويز سیدی، هم سطح با AMS)

-- 3-hop: $\Delta = +0.005$ (هم سطح با AMS)

دیتاست PPI (پروتئین-پروتئین):

-- SkipGATv2: $\Delta = +0.104$ (بهبود قابل توجه نسبت به AMS)

-- SkipGNN: $\Delta = -0.052$

-- GCN: $\Delta = -0.065$

دیتاست GDI (ژن-بیماری):


-- Heuristic: $\Delta = +0.013$ (بالاتر از AMS)

-- SkipGATv2: $\Delta = +0.008$

-- SkipGNN: $\Delta = -0.109$

نکته مهم: در دیتاست PPI، مدل SkipGATv2 با اختلاف $+0.104$ واحد درصد از AMS پیشی گرفته است. با توجه به اینکه SkipGATv2 در PPI تنها ۳۱ گام Adam در هر اپاک دریافت کرده (در مقایسه با ۲۵۵ گام AMS)، این برتری به عنوان شواهدی بر کارآمدی ذاتی مکانیزم توجه پویا تفسیر می شود، نه صرفاً نتیجه بودجه محاسباتی بیشتر. این نکته در فصل ششم به تفصیل بحث شده است.

۷-۳-۵: توزیع بین سیدی شکل ۷



شکل ۷-۵: توزیع بین سیدی Hard AUPRC برای تمام مدل ها (سیدهای ۴۲، ۱۲۳ و ۷).

این نمودار جعبه ای، پایداری مدل ها را در ۳ سید (۴۲، ۱۲۳، ۷) نشان می دهد.


مشاهدات:

-- در دیتاست DDI، جعبه های مدل های پیشنهادی ارتفاع بسیار کمی دارند (واریانس در حد 10^{-3} تا 10^{-4}) که نشان دهنده پایداری بالای یادگیری در گراف متراکم است.

-- در دیتاست های تنک تر (DTI و PPI)، ارتفاع جعبه ها کمی بازتر است (انحراف معیار 0.005 تا 0.021).

-- در دیتاست های تنک، جعبه های مدل های پیشنهادی با جعبه های GCN و SkipGNN هم پوشانی ندارند.

محدودیت آماری: با ۳ سید، امکان محاسبه فواصل اطمینان ۹۵٪ دقیق و آزمون های معناداری رسمی محدود است. عدم هم پوشانی جعبه ها به عنوان شاخص اولیه تمایز در نظر گرفته شده، ولی جایگزین آزمون های آماری رسمی نیست.



شکل ۵-۸: مقایسه AUROC در بانک یکنواخت و بانک سخت برای هفت مدل.

۵-۳-۸ شکل ۸: مقایسه بر حسب AUROC

این نمودار الگوی مشابه شکل ۱ را برای معیار AUROC تکرار می‌کند:

- در پنل یکنواخت، تمام مدل‌ها در محدوده 0.90 تا 0.98 فشرده هستند.
- در پنل سخت، عملکرد SkipGNN در تمام دیتاست‌ها کاهش می‌یابد.
- مدل‌های پیشنهادی در محدوده 0.76 تا 0.92 قرار دارند.


۵-۳-۹ شکل ۹: منحنی‌های یادگیری

این نمودار چهارپنلی، روند Val AUPRC را در طول اپاک‌های آموزش نشان می‌دهد.
مشاهدات کلیدی:

- **پنل DDI:** مدل‌های پیشنهادی به سرعت به سقف عملکردی (≈ 0.98) همگرا می‌شوند. GCN در سطح پایین‌تر (≈ 0.90) باقی می‌ماند.
- **پنل DTI:** همگرایی در اپاک‌های اولیه (۳ تا ۸) رخ می‌دهد. مدل 3-hop روند صعودی ملایم‌تری دارد.
- **پنل PPI:** AMS به سرعت همگرا می‌شود. SkipGATv2 روند صعودی پیوسته‌تری دارد.
- **پنل GDI:** پدیده قابل توجهی در مدل SkipGNN مشاهده می‌شود.

پدیده افت عملکرد در SkipGNN روی GDI: در پنل GDI، مدل مرجع SkipGNN از اپاک‌های اولیه با Val AUPRC بالا (≈ 0.93) شروع شده و سپس روند نزولی تدریجی را طی می‌کند تا جایی که توقف


Validation AUPRC learning curves (mean $\pm$ SD)



شکل ۹-۵: منحنی‌های یادگیری: روند Val AUPRC در طول اپاک‌های آموزش (میانگین $\pm$ انحراف معیار).

زود هنگام آموزش را متوقف می‌سازد. این الگو با فرضیه بن‌بست هندسی در گراف‌های دوقطبی (بخش ۲-۴-۱) هم‌خوان است: عملگر پرش باینری $\text{sign}(A^2)$ در گراف دوقطبی صرفاً اتصالات درون‌نوعی ایجاد می‌کند و با ادامه آموزش، این سیگنال‌های غیرمرتبط به تدریج بازنمایی گره‌ها را آلوده می‌سازند. **محدودیت تفسیر:** این مشاهده بر اساس ۳ سید است. برای اثبات قطعی این پدیده، تکرار با سیدهای بیشتر و تحلیل آماری رسمی ضروری است.

۵-۳-۱۰: شاخص F1 در آستانه بهینه



شکل ۵-۱۰: شاخص F1 در آستانه منجمد اعتبارسنجی (τ^*). هوریستیک به دلیل نداشتن آستانه احتمالی حذف شده است.

این نمودار شاخص F1 را در آستانه منجمد اعتبارسنجی (τ^*) گزارش می‌کند. هوریستیک به دلیل فاقد بودن آستانه احتمالی حذف شده است.

مشاهدات:



-- در DDI، شاخص F1 برای AMS، Contrastive و 3-hop به بالای 0.93 می‌رسد.

-- در GDI، مدل‌های 3-hop و Contrastive با F1 حدود 0.889 بالاترین تعادل را نشان می‌دهند.

-- در PPI، SkipGATv2 با F1 حدود 0.809 بالاترین تعادل را دارد.



۵-۴: تحلیل فضاهای نهفته با t-SNE

برای درک شهودی از چگونگی سازمان‌دهی فضا توسط انکودرها، امبدینگ‌های لایه آخر مدل‌ها در سید ۴۲ توسط الگوریتم t-SNE [۱۵] تصویرسازی شدند. پارامترهای تصویرسازی:



SkipGNN

GCN



SkipGATv2

AMS-SkipGNN

شکل ۱۱-۵: تصویرسازی t-SNE از امبدینگ لایه آخر روی دیتاست DTI (سید ۴۲). رنگ‌ها نوع موجودیت را در گراف دوقطبی نشان می‌دهند.

-- کاهش بعد از ۶۴ به ۲

-- نمونه برداری حداکثر ۴۰۰۰ گره

-- رنگ آمیزی بر اساس نوع موجودیت (مبدا/مقصد) در گراف های دو قطبی

-- $\text{perplexity} = \min(30, \max(5, N/10))$

-- $\text{init} = \text{"pca"}$

جدول ۵-۶: تحلیل تطبیقی ویژگی های بصری مانیفولد فضای نهفته

مدل	ساختار هندسی مشاهده شده	تفکیک نوع موجودیت	تفسیر
GCN	رشته ای و درهم تنیده	تفکیک ضعیف	محو هویت ساختاری گره ها
SkipGNN	دو قطب مجزا با مرز خشک	تفکیک ماکروسکوپی	تراکم ناشی از باینری سازی
AMS	مدولار با هسته و حاشیه	تفکیک پیوسته	وزن دهی پیوسته و حفظ تنوع
3-hop	پل های ارتباطی میان خوشه ها	تفکیک با اتصالات مرزی	اتصال خانواده های ساختاری
Contrastive	توزیع یکنواخت	توزیع متعادل	اثر زبان مقابله ای
SkipGATv2	جزایر خوشه ای مجزا	خوشه بندی تمیز	هرس یال های کم اهمیت

ملاحظات روش شناختی: تحلیل t-SNE توصیفی و کیفی است. برای ارزیابی کمی کیفیت فضای نهفته، معیارهایی مانند Silhouette Score، Alignment و Uniformity [۱۹]، یا دقت طبقه بندی k-NN روی فضای نهفته می توانند مکمل مفیدی باشند. این معیارها به عنوان کار آینده پیشنهاد می شوند.

۵-۵ خلاصه یافته های کلیدی فصل

جدول ۵-۷ خلاصه ای از بهبودهای کلیدی مدل های پیشنهادی نسبت به مدل مرجع SkipGNN را در معیار اصلی رتبه بندی (Hard AUPRC) نشان می دهد. مقادیر بهبود به واحد درصد (percentage points) بیان شده اند:

جدول ۵-۷: بهبود مطلق نسبت به SkipGNN در Hard AUPRC

دیتاست	SkipGNN	بهترین مدل پیشنهادی	بهبود مطلق (واحد درصد)	وضعیت آماری
DDI	0.724	AMS: 0.912	+0.188	برتری بدون هم پوشانی بازه ها
PPI	0.622	SkipGATv2: 0.778	+0.156	برتری بدون هم پوشانی بازه ها
GDI	0.720	SkipGATv2: 0.837	+0.117	برتری مرزی
DTI	0.695	AMS، SkipGATv2 و 3-hop هم سطح	+0.10 تا +0.11	هم سطح آماری (بازه های هم پوشان)

یافته های مکمل:

-- در دیتاست PPI، SkipGATv2 با اختلاف +0.104 واحد درصد از AMS پیشی گرفته است. این برتری با وجود گام های بهینه سازی کمتر (۳۱ در برابر ۲۵۵ گام در هر اپاک) رخ داده است.

-- در دیتاست GDI، هوریستیک تحلیلی با 0.842 بالاتر از تمام مدل های عصبی است.

-- در دیتاست DDI، AMS با 0.912 برترین عملکرد را در میان مدل‌های عصبی دارد.

فصل ۶

بحث، تحلیل پاشنه‌های آشیل، نتیجه‌گیری و افق‌های آینده

۶-۱ بحث مکانیکی و تبیین چرایی نتایج (Mechanistic Discussion)

یافته‌های تجربی ارائه‌شده در فصل پنجم، پنج فرضیه علمی مطرح‌شده در فصل اول را تا حد زیادی تایید می‌کنند. واکاوی رفتار مدل‌ها در چهار بنچمارک زیستی، سه بینش بنیادین تئوریک پیرامون دینامیک یادگیری روی گراف‌های زیست‌مولکولی را آشکار می‌سازد.

۶-۱-۱ نقش عملگر پیوسته تخصیص منابع در مهار سوگیری هاب‌ها

یکی از مهم‌ترین یافته‌های این پژوهش، تاثیر جایگزینی عملگر باینری $\text{sign}(AA^T)$ با عملگر پیوسته تخصیص منابع $(W_2 = AD^{-1}A^T)$ است. در گراف‌های زیستی که دارای توزیع درجه بی‌مقیاس هستند، گره‌های هاب (مانند داروهای پرعارضه یا پروتئین‌های چندمنظوره) به‌طور مصنوعی تعداد زیادی مسیر ۲-گام ایجاد می‌کنند.

عملگر باینری SkipGNN، تمام این مسیرها را با وزن یکسان (1.0) لحاظ می‌کند که منجر به پدیده «اشباع سیگنال» در گره‌های هاب می‌شود. در مقابل، عملگر تخصیص منابع با تقسیم وزن هر مسیر بر درجه گره واسط $(1/d_k)$ ، به‌عنوان یک فیلتر پایین‌گذر توپولوژیک عمل کرده و سیگنال‌های اختصاصی (از طریق گره‌های واسط با درجه پایین) را تقویت می‌کند. این مکانیزم دلیل اصلی جهش عملکرد مدل AMS در دیتاست متراکم DDI (از 0.724 به 0.912 در آزمون سخت، معادل بهبود 0.188+ واحد درصد) است، جایی که تداخلات دارویی از طریق مسیرهای چندگانه و پیچیده شکل می‌گیرند.

۶-۱-۲ حل بن‌بست هندسی دوقطبی با مسیرهای ۳-گام

همان‌طور که در بخش ۲-۴-۱ اثبات شد، در گراف‌های دوقطبی (DTI و GDI)، ماتریس A^2 ساختاری بلوکی-قطری دارد و فاقد هرگونه یال میان موجودیت‌های ناهم‌نوع است. مدل مرجع SkipGNN با تکیه بر این ماتریس، در عمل دچار افت عملکرد تدریجی می‌شد (مشاهده‌شده در منحنی‌های یادگیری GDI در شکل ۹).

مدل‌های ThreeHopSkipGNN و AMS-SkipGNN با تزریق صریح مسیرهای ۳-گام $(W_3 = W_2 D^{-1} A)$ ، این بن‌بست هندسی را شکستند. مسیر $p' \rightarrow d' \rightarrow p$ (دارو $\leftarrow$ پروتئین واسط $\leftarrow$ داروی واسط $\leftarrow$ پروتئین هدف) اولین مسیر توپولوژیک غیرمستقیم برای دسترسی به تارگت کاندید است. موفقیت این مدل‌ها در دیتاست DTI (کسب Hard AUPRC برابر با 0.803 برای 3-hop

و 0.798 برای AMS) نشان می‌دهد که دسترسی انکودر به اطلاعات نوع مخالف، پیش‌شرط یادگیری در گراف‌های دوقطبی است.

۳-۱-۶ هم‌افزایی گیتینگ تطبیقی و دیکودر تانسوری تعاملی

تحلیل نردبان ابلیشن (شکل ۲) یک الگوی قابل توجه را نشان داد: افزودن پرش وزن‌دار (گام ۱) و گیتینگ تطبیقی (گام ۲) به‌تنهایی و بدون اصلاح دیکودر، نه‌تنها بهبودی ایجاد نکرد، بلکه منجر به افت جزئی عملکرد (از 0.703 به 0.686 در DTI) شد.

تبیین مکانیکی: پرش پیوسته RA و گیتینگ، ظرفیت بازنمایی (Representation Capacity) شبکه را به‌شدت افزایش می‌دهند و سیگنال‌های توپولوژیک غنی‌تری تولید می‌کنند. با این حال، دیکودر خطی الحاقی ($[E_u \parallel E_v]$) فاقد ظرفیت لازم برای پردازش این سیگنال‌های پیچیده و غیرخطی است. در نتیجه، شبکه دچار بیش‌برازش روی نویزهای فرکانس بالای گراف پرش می‌شود.

جهش اصلی در گام ۳ (افزودن دیکودر تانسوری ۴گانه) رخ داد. مولفه‌های ضربی ($E_u \odot E_v$) و فاصله‌ای ($|E_u - E_v|$) در این دیکودر، تقارن ذاتی تعاملات بیوشیمیایی (مانند مدل قفل‌وکلید) را به‌صورت صریح مدل‌سازی می‌کنند. این یافته نشان می‌دهد که در معماری‌های GNN، ارتقای انکودر باید همواره با ارتقای متناسب ظرفیت دیکودر همراه باشد تا از پدیده «تنگنای اطلاعاتی» (Information Bottleneck) جلوگیری شود.

۴-۱-۶ تمایز عملکرد بین دیتاست‌ها و کارآمدی SkipGATv2

یکی از یافته‌های مهم این پژوهش، تفاوت الگوی برتری مدل‌ها در دیتاست‌های مختلف است:

-- **DDI (گراف همگن متراکم):** مدل AMS با 0.912 برترین عملکرد را دارد، و برتری آن نسبت به سایر مدل‌های پیشنهادی کاملاً آشکار است.

-- **DTI (گراف دوقطبی تنگ):** سه مدل AMS، SkipGATv2 و 3-hop با میانگین‌های 0.798، 0.804 و 0.803 از نظر آماری هم‌سطح هستند (بازه‌های انحراف معیار هم‌پوشان).

-- **PPI (گراف همگن مدولار):** SkipGATv2 با 0.778 بهترین عملکرد را دارد که بهبود قابل توجه 0.104+ واحد درصدی نسبت به AMS نشان می‌دهد.

-- **GDI (گراف دوقطبی کلان):** هوریستیک تحلیلی با 0.842 بالاتر از تمام مدل‌های عصبی است.

تحلیل SkipGATv2 در PPI: نکته مهم این است که برتری SkipGATv2 در PPI علی‌رغم گام‌های بهینه‌سازی کمتر رخ داده است. این مدل در PPI تنها ۳۱ گام Adam در هر اپاک دریافت کرده (در مقایسه با ۲۵۵ گام AMS، به دلیل بچ‌سایز ۱۰۲۴ در برابر ۱۲۸). این برتری با وجود گام‌های بهینه‌سازی

کمتر، به عنوان شواهدی بر کارآمدی ذاتی مکانیزم توجه پویا در گراف‌های همگن مدولار تفسیر می‌شود، نه صرفاً نتیجه بودجه محاسباتی بیشتر.

۶-۲ تحلیل پاشنه‌های آشیل و محدودیت‌های روش‌شناختی

یک گزارش علمی معتبر موظف است محدودیت‌ها و شرایط مرزی مدل‌های خود را به صورت شفاف و بدون اغراق تبیین کند. تحلیل نتایج، چهار چالش و محدودیت مهم را آشکار می‌سازد که مسیرهای اصلی برای کارهای آینده هستند.

۶-۲-۱ چالش گراف‌های کلان و تنک: برتری هوریستیک در GDI

یکی از مهم‌ترین و صادقانه‌ترین یافته‌های این پژوهش، عملکرد خیره‌کننده هوریستیک تحلیلی Re-source Allocation در دیتاست ژن-بیماری (GDI) است. در این گراف دوقطبی کلان (19,783 نود)، هوریستیک ۳-گام بدون هیچ پارامتر یادگیرنده‌ای، Hard AUPRC برابر با 0.842 کسب کرد که بالاتر از تمام مدل‌های عصبی (از جمله SkipGATv2 با 0.837 و AMS با 0.829) است.

تحلیل ریشه‌ای: این پدیده که در ادبیات GNN‌ها به عنوان «محدودیت سوگیری القایی» (Inductive Bias Limitation) شناخته می‌شود، نشان می‌دهد که در گراف‌های به شدت تنک و کلان با ویژگی‌های هویتی، مکانیزم Message-Passing در GNN‌ها (حتی با وجود پرش‌های وزنی و گیتینگ) دچار پدیده «رقیق شدن سیگنال» (Signal Dilution) می‌شود. هوریستیک RA ذاتاً یک شمارشگر دقیق و بهینه مسیرهای ۳-گام است و در غیاب ویژگی‌های غنی گره‌ای (Node Features)، توپولوژی خالص را بهتر از یک شبکه عصبی ۲-لایه استخراج می‌کند.

تبیین صادقانه: این یافته نشان می‌دهد که معماری‌های عصبی برای غلبه بر هوریستیک‌ها در گراف‌های کلان، نیازمند تلفیق با ویژگی‌های معنادار بیوشیمیایی هستند تا صرفاً توپولوژی. به بیان دیگر، در این پژوهش با انتخاب آگاهانه ویژگی‌های هویتی (بخش ۱-۵-۲)، ما به طور عمدی مزیت ویژگی‌های بیوشیمیایی را حذف کردیم تا اثر خالص معماری را بسنجیم. این محدودیت به صراحت به عنوان مسیر کار آینده ذکر شده است.

۶-۲-۲ محدودیت ویژگی‌های هویتی (One-Hot) و افت مکانیزم توجه در گراف کلان

در دیتاست PPI، مدل SkipGATv2 با کسب Hard AUPRC برابر با 0.778 بهترین عملکرد را در میان تمام مدل‌ها داشت که نشان‌دهنده کارآمدی مکانیزم توجه پویا در گراف‌های همگن با ساختار مدولار است. با این حال، همین مدل در دیتاست کلان GDI دچار افت عملکرد شد و نتوانست از هوریستیک پیشی بگیرد.

تبیین تئوریک: این پدیده به «بیش تطبیق پارامتری توجه» (Attention Over-parameterization)

معروف است. زمانی که ویژگی‌های ورودی گره‌ها صرفاً بردارهای هویتی (One-Hot) باشند، مکانیزم توجه در گراف‌های بسیار بزرگ فاقد سیگنال‌های معنادار اولیه برای محاسبه ضرایب توجه پایدار است. در نتیجه، مدل به جای یادگیری الگوهای ساختاری، دچار نویز محاسباتی می‌شود. این محدودیت مستقیماً ناشی از انتخاب روش‌شناختی این پژوهش مبنی بر ایزوله‌سازی اثرات توپولوژی (بخش ۱-۵-۲) است و در صورت افزودن ویژگی‌های پیوسته (مانند امبدینگ‌های توالی پروتئین)، برطرف خواهد شد.

۳-۲-۶ محدودیت‌های آماری و تعداد سیدها

تعداد سیدها: به دلیل هزینه محاسباتی بالای پروتکل ارزیابی دوگانه (ساخت بانک منفی سخت، آموزش ۷ مدل، و ۴ دیتاست بر روی GPU T4)، آزمایش‌ها با ۳ سید تصادفی (۴۲، ۱۲۳، ۷) انجام شدند. این تعداد از نظر ادبیات GNN (که معمولاً ۵ تا ۱۰ سید مرسوم است) کمتر از حد مطلوب است.

آزمون‌های آماری: در این گزارش، معیار تمایز آماری، عدم هم‌پوشانی بازه‌های میانگین $\pm$ انحراف معیار بوده است. آزمون‌های معناداری رسمی (مانند paired t-test یا Wilcoxon signed-rank test) به دلیل تعداد محدود سیدها انجام نشده‌اند. این محدودیت به‌ویژه در دیتاست DTI اهمیت دارد، جایی که سه مدل پیشنهادی بازه‌های هم‌پوشان دارند و برتری یکی بر دیگری از نظر آماری قابل اثبات نیست. **راهکار پیشنهادی:** در کارهای آینده، اجرای آزمایش‌ها با حداقل ۵ سید و گزارش p-value رسمی برای هر مقایسه، ضروری است.

۴-۲-۶ محدودیت مقیاس‌پذیری

بزرگ‌ترین گراف بررسی‌شده در این پژوهش حدود ۲۰ هزار نود داشت. تعمیم این معماری‌ها به گراف‌های میلیون‌نودی (مانند کل اینتراکتوم انسان) نیازمند بهینه‌سازی‌های سطوح پایین‌تر سخت‌افزاری (مانند FlashAttention برای گراف‌ها) و تکنیک‌های نمونه‌برداری زیرگراف (Subgraph Sampling) است که در این پروژه بررسی نشده‌اند.

الگوریتم Chunking پیاده‌سازی‌شده برای SkipGATv2 (بخش ۳-۳-۴)، قله مصرف حافظه را از $O(|\mathcal{E}|)$ به $O(\text{chunk})$ کاهش می‌دهد، اما زمان آموزش همچنان با تعداد یال‌های پرش به صورت خطی رشد می‌کند.

۳-۶ نتیجه‌گیری و پاسخ به پرسش‌های پژوهش

این پروژه با هدف بازبینی نقادانه و بازطراحی ساختاری مدل SkipGNN در پیش‌بینی تعاملات زیست‌مولکولی اجرا گردید. نتایج به‌دست‌آمده به پنج پرسش بنیادین پژوهش به شرح زیر پاسخ می‌دهند:

جدول ۱-۶: خلاصه پاسخ‌های پژوهش به پرسش‌های پنج‌گانه مطرح‌شده در فصل اول

پرسش	فرضیه مطرح‌شده	نتیجه تجربی و وضعیت اثبات
RQ1 (چگالی توپولوژیک پرس)	جایگزینی sign با پرس وزن دار RA مانع از افت در منفی‌های سخت می‌شود.	تایید مشروط: پرس RA به‌تنهایی کافی نیست، اما در ترکیب با دیکودر تانسوری (مدل AMS)، منجر به بهبود 0.188+ واحد درصدی در DDI و 0.103+ واحد درصدی در DTI نسبت به SkipGNN شد.
RQ2 (دوگانگی ساختار دوقطبی)	مسیرهای ۳-گام بن‌بست گام زوج در گراف‌های دوقطبی را جبران می‌کنند.	تایید: مدل 3-hop با صراحت این بن‌بست را هدف قرار داد و در DTI به Hard AUPRC برابر با 0.803 دست یافت (هم‌سطح با AMS و SkipGATv2).
RQ3 (ظرفیت دیکودر)	دیکودر تانسوری ۴‌گانه تعاملات غیرخطی متقارن را تفکیک می‌کند.	تایید: نردبان ابلیشن نشان داد که جهش اصلی عملکرد (از 0.686 به 0.788 در DTI) دقیقاً در مرحله افزودن دیکودر تانسوری رخ می‌دهد.
RQ4 (پایداری فضای بازنمایی)	زیان InfoNCE مانع از انحراف و چسبندگی امیدینگ‌های هاب می‌شود.	تایید کیفی: تحلیل بصری t-SNE نشان داد که مدل Contrastive دارای توزیع یکنواخت‌تر (Uniformity) در فضای نهفته است، هرچند در معیارهای کمی رتبه‌بندی، برتری مطلق نسبت به AMS نداشت.
RQ5 (اعتبار پروتکل ارزیابی)	ارزیابی یکنواخت همراه‌کننده است و ارزیابی سخت استاندارد واقعی است.	تایید: عملکرد SkipGNN که در آزمون یکنواخت رقابتی به‌نظر می‌رسید (0.929 در DTI)، در آزمون سخت به‌شدت افت کرد (0.695)، که سوگیری پروتکل‌های پیشین را تایید می‌کند.

پیام علمی محوری: در پیش‌بینی تعاملات زیست‌مولکولی روی گراف، طراحی توپولوژیک عملگرهای پرس بر پایه نوع گراف (همگن در برابر دوقطبی) و استفاده از دیکودرهای تعاملی تانسوری، نقشی تعیین‌کننده ایفا می‌کنند. با این حال، در گراف‌های کلان و به‌شدت تنک، هوریستیک‌های تحلیلی همچنان رقبای جدی برای مدل‌های عصبی مبتنی بر توپولوژی خالص هستند.

شفاف‌سازی مهم: مدل AMS عمیق‌ترین اعتبارسنجی ساختاری (نردبان ابلیشن کامل) را در میان چهار مدل دارد و در دیتاست DDI به‌وضوح برترین مدل عصبی است. با این حال، از نظر امتیاز خام Hard AUPRC، در دیتاست‌های DTI، PPI و GDI با SkipGATv2 هم‌سطح یا در محدوده انحراف معیار آن قرار دارد. این تنوع عملکردی، غنای یافته‌های پژوهش است و نشان می‌دهد که یک معماری واحد نمی‌تواند در تمام ساختارهای گرافی برتری مطلق داشته باشد.

۴-۶ افق‌های پژوهشی و کارهای آینده

بر پایه یافته‌ها و محدودیت‌های شناسایی‌شده در این پروژه، مسیرهای پژوهشی زیر به‌عنوان توسعه‌های آتی پیشنهاد می‌گردد:

۴-۶-۱ تزریق ویژگی‌های چندوجهی بیوشیمیایی پیش‌آموزش‌دیده

مهم‌ترین محدودیت این پژوهش، اتکا به ویژگی‌های هویتی (One-Hot) بود. در کارهای آینده، افزودن ویژگی‌های پیوسته استخراج‌شده از مدل‌های زبانی بزرگ زیستی می‌تواند پاشنه آشیل مدل‌ها در

گراف‌های کلان (مانند GDI) را برطرف کند. این ویژگی‌ها شامل:

-- برای مولکول‌های دارویی: اثرانگشت‌های ساختاری مورگان [۱۰] و امبدینگ‌های مدل ChemBERTa [۳] برای کپچر کردن خصوصیات شیمیایی.

-- برای توالی‌های پروتئینی: امبدینگ‌های لایه‌های آخر مدل‌های زبانی پروتئین نظیر ESM-2 [۱۳] یا ProtTrans [۴].

-- برای ژن‌ها: امبدینگ‌های Gene Ontology یا الگوهای بیان ژن.

این تلفیق می‌تواند افت SkipGATv2 در گراف‌های کلان (بخش ۶-۲-۲) را جبران کند.

۶-۴-۲ معماری ترکیبی ۳-گام و یادگیری خودنظارتی

ترکیب عملگرهای مسیر طول فرد در مدل ThreeHopSkipGNN با قید یکنواختی کروی در ContrastiveSkipGNN به‌منظور ایجاد مدلی که همزمان فیزیک گراف دوقطبی را بشناسد و فضا را در برابر بیش‌برازش هاب‌ها تنظیم نماید. این ترکیب می‌تواند به عنوان یک معماری هیبریدی در گراف‌های دوقطبی تنک عملکرد بهینه ارائه دهد.

۶-۴-۳ تعمیم به گراف‌های دانش ناهمگن چندنوعی

گسترش عملگرهای پرش چندمقیاسی به شبکه‌های دارای ده‌ها نوع موجودیت همزمان (دارو، ژن، بیماری، مسیر بیولوژیکی، فنوتیپ و عوارض جانبی) در قالب شبکه‌های عصبی گراف رابطه‌ای (Relational GNNs) [۱۷] و پیش‌بینی چندتکلیفی (Multi-task Learning).

۶-۴-۴ توسعه الگوریتم‌های شتاب‌دهی سخت‌افزاری

بازنویسی لایه‌های اتنشن تنک (مانند SparseGATv2Layer) با کرنل‌های ادغام‌شده CUDA/Triton (مشابه FlashAttention) جهت حذف کامل سربار محاسباتی و امکان آموزش روی گراف‌های بالاتر از ۱۰۰ هزار گره بدون نیاز به تکنیک‌های Chunking.

۶-۴-۵ اعتبارسنجی آماری با سیدهای بیشتر

اجرای آزمایش‌های نهایی با حداقل ۵ تا ۱۰ سید تصادفی و گزارش آزمون‌های معناداری رسمی (paired t-test یا Wilcoxon signed-rank) برای هر مقایسه مدل. این کار به‌ویژه برای دیتاست‌هایی مانند DTI که در آن بازه‌های انحراف معیار هم‌پوشان هستند، ضروری است.

۶-۴-۶ معیارهای کمی برای فضای نهفته

افزودن معیارهای کمی مانند Silhouette Score، Alignment و Uniformity [۱۹]، یا دقت طبقه‌بندی k-NN روی فضای نهفته به عنوان مکمل تحلیل بصری t-SNE. این معیارها می‌توانند تبیین دقیق‌تری از کیفیت فضاها را نهفته مدل‌های مختلف ارائه دهند.

مراجع

- [1] A.-L. Barabási and R. Albert. "Emergence of Scaling in Random Networks". In: *Science* 286.5439 (1999), pp. 509–512. DOI: 10.1126/science.286.5439.509.
- [2] S. Brody, U. Alon, and E. Yahav. "How Attentive Are Graph Attention Networks?" In: *International Conference on Learning Representations (ICLR)*. 2022.
- [3] S. Chithrananda, G. Grand, and B. Ramsundar. "ChemBERTa: Large-Scale Self-Supervised Pretraining for Molecular Property Prediction". In: *Machine Learning for Molecules Workshop at NeurIPS*. 2020.
- [4] A. Elnaggar, M. Heinzinger, C. Dallago, G. Rehawi, Y. Wang, L. Jones, et al. "ProtTrans: Toward Understanding the Language of Life through Self-Supervised Learning". In: *IEEE Transactions on Pattern Analysis and Machine Intelligence* 44.10 (2022), pp. 7112–7127. DOI: 10.1109/TPAMI.2021.3095381.
- [5] J. Gilmer, S. S. Schoenholz, P. F. Riley, O. Vinyals, and G. E. Dahl. "Neural Message Passing for Quantum Chemistry". In: *Proceedings of the 34th International Conference on Machine Learning*. Vol. 70. Proceedings of Machine Learning Research. 2017, pp. 1263–1272.
- [6] K. Huang. *SkipGNN Source Code*. <https://github.com/kexinhuang12345/SkipGNN>. 2020.
- [7] K. Huang, C. Xiao, L. M. Glass, and M. Zitnik. "SkipGNN: Predicting Molecular Interactions with Skip-Graph Networks". In: *Scientific Reports* 10 (2020), p. 21092. DOI: 10.1038/s41598-020-77766-9.
- [8] S. Ioffe and C. Szegedy. "Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift". In: *Proceedings of the 32nd International Conference on Machine Learning*. Vol. 37. Proceedings of Machine Learning Research. 2015, pp. 448–456.

- [9] T. N. Kipf and M. Welling. “Semi-Supervised Classification with Graph Convolutional Networks”. In: *International Conference on Learning Representations (ICLR)*. 2017.
- [10] G. Landrum. *RDKit: Open-Source Cheminformatics*. <https://www.rdkit.org>. 2016.
- [11] J. Li, H. Shomer, H. Mao, S. Zeng, Y. Ma, N. Shah, J. Tang, and D. Yin. “Evaluating Graph Neural Networks for Link Prediction: Current Pitfalls and New Benchmarking”. In: *Advances in Neural Information Processing Systems (NeurIPS), Datasets and Benchmarks Track*. 2023.
- [12] Q. Li, Z. Han, and X.-M. Wu. “Deeper Insights into Graph Convolutional Networks for Semi-Supervised Learning”. In: *Proceedings of the AAAI Conference on Artificial Intelligence*. Vol. 32. 1. 2018. DOI: 10.1609/aaai.v32i1.11604.
- [13] Z. Lin, H. Akin, R. Rao, B. Hie, Z. Zhu, W. Lu, et al. “Evolutionary-Scale Prediction of Atomic-Level Protein Structure with a Language Model”. In: *Science* 379.6637 (2023), pp. 1123–1130. DOI: 10.1126/science.ade2574.
- [14] K. Luck, D.-K. Kim, L. Lambourne, K. Spirohn, B. E. Begg, W. Bian, et al. “A Reference Map of the Human Binary Protein Interactome”. In: *Nature* 580.7803 (2020), pp. 402–408. DOI: 10.1038/s41586-020-2188-x.
- [15] L. van der Maaten and G. Hinton. “Visualizing Data using t-SNE”. In: *Journal of Machine Learning Research* 9.86 (2008), pp. 2579–2605.
- [16] J. Piñero, J. M. Ramírez-Anguita, J. Saüch-Pitarch, F. Ronzano, E. Centeno, F. Sanz, and L. I. Furlong. “The DisGeNET Knowledge Platform for Disease Genomics: 2019 Update”. In: *Nucleic Acids Research* 48.D1 (2020), pp. D845–D855. DOI: 10.1093/nar/gkz1021.
- [17] M. Schlichtkrull, T. N. Kipf, P. Bloem, R. van den Berg, I. Titov, and M. Welling. “Modeling Relational Data with Graph Convolutional Networks”. In: *The Semantic Web*. Vol. 10843. Lecture Notes in Computer Science. Springer, 2018, pp. 593–607. DOI: 10.1007/978-3-319-93417-4_38.
- [18] Stanford SNAP Group. *BioSNAP Datasets: Stanford Biomedical Network Dataset Collection*. <https://snap.stanford.edu/biodata/>. 2018.

- [19] T. Wang and P. Isola. “Understanding Contrastive Representation Learning through Alignment and Uniformity on the Hypersphere”. In: *Proceedings of the 37th International Conference on Machine Learning*. Vol. 119. Proceedings of Machine Learning Research. 2020, pp. 9929–9939.
- [20] D. J. Watts and S. H. Strogatz. “Collective Dynamics of ‘Small-World’ Networks”. In: *Nature* 393.6684 (1998), pp. 440–442. DOI: 10.1038/30918.
- [21] T. Zhou, L. Lü, and Y.-C. Zhang. “Predicting Missing Links via Local Information”. In: *The European Physical Journal B* 71.4 (2009), pp. 623–630. DOI: 10.1140/epjb/e2009-00335-8.

Abstract

Title: Redesigning Skip-Graph Neural Networks for Predicting Biomolecular Interactions

Predicting biomolecular interactions—including drug–target, drug–drug, protein–protein, and gene–disease links—is a core problem in systems biology and computational drug discovery. SkipGNN (Huang et al., 2020) injects a 2-hop skip graph into a graph neural network and reports strong results on standard benchmarks. A theoretical and empirical audit in this work identifies four structural limits of that model: a geometric dead-end of the A^2 operator on bipartite graphs, loss of density information under binarization, a linear decoder bottleneck, and degree bias in a uniform evaluation protocol.

Four models are implemented in one leak-free pipeline: AMS-SkipGNN (resource-allocation skip, adaptive gating, four-way tensor decoder), SkipGATv2 (sparse dynamic edge attention), ThreeHopSkipGNN (1/2/3-hop multi-scale paths), and ContrastiveSkipGNN (symmetric InfoNCE). Evaluation uses a dual-bank protocol (uniform negatives and degree-aware hard negatives) on DTI, DDI, PPI, and GDI with three random seeds.

On the hard bank the proposed models improve over SkipGNN: on DDI, AMS reaches 0.912 versus 0.724; on PPI, SkipGATv2 reaches 0.778 versus 0.622; on DTI and GDI the gains are about +0.10 to +0.12 percentage points. On DTI, AMS, SkipGATv2, and 3-hop are statistically on par (overlapping standard-deviation intervals). On GDI, the analytical resource-allocation heuristic attains 0.842 and outperforms every neural model—an important limit of identity-feature GNNs on large sparse graphs.

Keywords: link prediction, graph neural networks, SkipGNN, bipartite graphs, resource allocation, dual-bank evaluation